Modélisation mathématique d'un environnement dynamique : Une approche fonctionnelle pour la quantification de l'état de santé

Karl Garrido-Andersson *

6 septembre 2026

Résumé

Cet article propose un cadre mathématique formel pour la modélisation d'un environnement dynamique et de son évolution temporelle. Nous introduisons une hiérarchie de trois objets fondamentaux : le *cadre*, les *événements* et l'*axe temporel*.

Chaque événement est caractérisé par cinq attributs quantifiables que l'opérateur Γ extrait ou calcule, en intégrant directement la dynamique temporelle dans l'expression de la gravité. Pour capturer les interactions entre événements coexistants (amplification, neutralisation, rétroaction), nous définissons une matrice d'interaction $\mathbf{W}(t)$.

L'opérateur ζ synthétise l'ensemble de ces informations en un scalaire normalisé (l'*état de santé* de l'environnement) à valeurs dans $(-1, 1)$, fondé sur la fonction tanh. Une validation expérimentale préliminaire conforte les améliorations apportées (dilatation, splines adaptatives, clusterisation) et identifie les limites actuelles du modèle.

Note sur les contributions.

Les éléments suivants constituent des apports originaux de l'auteur : la forme fonctionnelle de Γ avec gravité résiduelle temporelle, la procédure de calibration par cluster, l'opérateur ζ_λ avec dilatation, la construction du drap variationnel de poids et la stratégie de nœuds adaptatifs aux discontinuités. Les résultats suivants sont issus de la littérature : propriétés de tanh, algorithme k-means [6], règle Q-Learning [4], splines cubiques [5], fonctionnelle de Dirichlet [7].

*L'auteur certifie que l'intégralité du raisonnement mathématique, du modèle formel et des constructions algorithmiques présentés dans ce document sont issus de recherches personnelles originales sauf mention contraire.

Table des matières

1 Introduction **4**
- 1.1 Problématique et objectifs . . . 4
- 1.2 Complexité de la représentation et approche retenue . . . 4
- 1.3 Applications et enjeux . . . 4
- 1.4 Contributions principales . . . 4

2 Cadre de travail et définitions fondamentales **5**
- 2.1 Objets mathématiques de base . . . 5
- 2.2 Axe temporel et dynamique . . . 5

3 Caractérisation des événements **8**
- 3.1 Les cinq attributs d'un événement . . . 8
- 3.2 L'opérateur de caractérisation Γ . . . 8
- 3.3 Intégration de la dynamique temporelle dans Γ . . . 8
- 3.4 Calibration des hyper-paramètres par cluster d'événements . . . 9
  - 3.4.1 Introduction . . . 9
- 3.5 Construction lexicale des clusters . . . 13
  - 3.5.1 Introduction . . . 13
  - 3.5.2 Développement . . . 13
- 3.6 Reformulation de l'environnement dynamique . . . 14

4 Interactions entre événements **15**
- 4.1 Types d'interactions . . . 15
- 4.2 Matrice d'interaction . . . 15

5 Cadre algorithmique **17**

6 L'état de santé d'un environnement **18**
- 6.1 Introduction . . . 18
- 6.2 Motivation et définition . . . 18
- 6.3 L'opérateur ζ . . . 18
- 6.4 Choix de tanh et propriétés associées . . . 19
- 6.5 Poids statiques et normalisation L^1 . . . 19
  - 6.5.1 Introduction . . . 19
  - 6.5.2 Définition et interprétation des poids . . . 20
  - 6.5.3 Normalisation L^1 et propriétés . . . 20
- 6.6 Construction d'un drap de poids par minimisation variationnelle . . . 20
  - 6.6.1 Introduction . . . 20
  - 6.6.2 Hypothèse de régularité . . . 20
  - 6.6.3 Rugosité locale et mesure des variations . . . 20
  - 6.6.4 Utilité de la rugosité locale $c(f)$ . . . 21
  - 6.6.5 Illustration de la rugosité locale sur deux cas représentatifs . . . 21
  - 6.6.6 Fonctionnelle d'énergie et drap optimal . . . 23
  - 6.6.7 Normalisation par la taille du domaine . . . 23
  - 6.6.8 Forme paramétrique par défaut et prédiction . . . 24
- 6.7 Critère d'asymétrie . . . 25
- 6.8 Expression complète de ζ . . . 26
- 6.9 Résultats préliminaires . . . 26
  - 6.9.1 Analyse des hyperparamètres de la loi de gravité . . . 28
  - 6.9.2 Draps variationnels des poids statiques ω_i . . . 29

7 Extensions du modèle **33**
7.1 Introduction . . . 33
7.2 Ajustement de la sensibilité par dilatation . . . 33
7.3 Lissage temporel par interpolation . . . 39
7.3.1 Lagrange et phénomène de Runge . . . 39
7.3.2 Splines cubiques - méthode recommandée . . . 39
7.3.3 Splines adaptatives aux discontinuités . . . 40
7.4 Apprentissage par validation croisée K-fold . . . 43
7.4.1 Introduction . . . 43
7.4.2 Analyse des performances du modèle . . . 43
7.5 Apprentissage par Q-Learning . . . 45
7.5.1 Principes fondamentaux . . . 45
7.5.2 L'Équation de Bellman et la mise à jour des valeurs . . . 46
7.5.3 Le dilemme Exploration vs Exploitation . . . 46
7.5.4 Application au modèle fonctionnel de quantification de l'état de santé . . . 47
7.5.5 Analyse des résultats . . . 47
7.6 Adoption d'un nouvel événement . . . 51

8 Synthèse du modèle **52**

9 Discussion et conclusion **53**
9.1 Synthèse des contributions . . . 53
9.2 Limites actuelles du modèle . . . 53
9.3 Perspectives . . . 54
9.4 Conclusion . . . 54

Annexes **55**

Bibliographie **56**

1 Introduction

Toute tentative de modélisation d'un phénomène réel commence par la nécessité de formaliser ce qui n'est, au premier abord, qu'intuition. L'environnement d'un individu ou d'un système est constitué d'événements, de structures et d'interactions qui se déploient dans le temps et dans l'espace. Avant de construire un modèle opérationnel, il convient d'en établir les fondements conceptuels et mathématiques.

1.1 Problématique et objectifs

L'objectif central est de modéliser l'**état de santé** d'un environnement (Définition 6.1) : une grandeur synthétique quantifiant sa propension à évoluer positivement ou négativement à un instant donné. Un tel indicateur normalisé présente un intérêt direct dans tout contexte d'anticipation d'un système complexe comme un marché financier, un écosystème ou encore une organisation industrielle.

1.2 Complexité de la représentation et approche retenue

La difficulté réside dans la diversité des environnements : certains sont tangibles (une ville, une forêt), d'autres intangibles (un réseau social, un marché boursier). Nous adoptons une **représentation événementielle** : l'environnement est entièrement décrit par ses événements constitutifs, chacun caractérisé par cinq attributs quantifiables, sans modéliser explicitement le cadre spatial.

1.3 Applications et enjeux

- Finance : quantifier l'état d'un marché à partir d'événements macroéconomiques pour anticiper la direction d'un actif.
- Écologie : évaluer la résilience d'un écosystème face aux perturbations et estimer son point de bascule.
- Gestion de risques : synthétiser les incidents opérationnels en un indicateur unique, compréhensible et actionnable.

1.4 Contributions principales

- Formalisation mathématique d'un environnement dynamique sur $\tau = \mathbb{R}^+$.
- Opérateur Γ avec gravité résiduelle temporelle, intégrant la durée restante directement dans l'expression de la gravité.
- Matrice d'interaction $\mathbf{W}(t)$, formalisant les effets croisés entre événements coexistants.
- Opérateur ζ à valeurs dans $(-1, 1)$, fondé sur tanh.
- Drap variationnel de poids, permettant d'attribuer un poids initial à tout nouvel événement par minimisation de la fonctionnelle de Dirichlet normalisée.

2 Cadre de travail et définitions fondamentales

2.1 Objets mathématiques de base

Définition 2.1 (Environnement)**.** *[Contribution originale de l'auteur.]*

Un environnement *est un couple* $E = (\mathcal{C},\ \{e_1, \ldots, e_N\})$*, où* $\mathcal{C}$ *désigne le* cadre *et* $\{e_i\}_{i=1}^{N}$ *est l'ensemble fini de ses* événements*, avec* $N \in \mathbb{N}^*$*.*

Remarque 2.1. *Une telle définition se veut statique. La dépendance temporelle est introduite en Section 2.2.*

Définition 2.2 (Cadre)**.** *[Contribution originale de l'auteur.]*

Le cadre $\mathcal{C}$ *est la limite arbitraire que l'utilisateur impose à l'étude de l'environnement. Il peut être géographique, thématique ou de toute autre nature. C'est une décision subjective exogène au modèle.*

Définition 2.3 (Événement)**.** *[Contribution originale de l'auteur.]*

Un événement *est la plus petite entité distinctement identifiable au sein de l'environnement. Chaque événement* e *est caractérisé par cinq attributs quantifiables présentés en Section 3.*

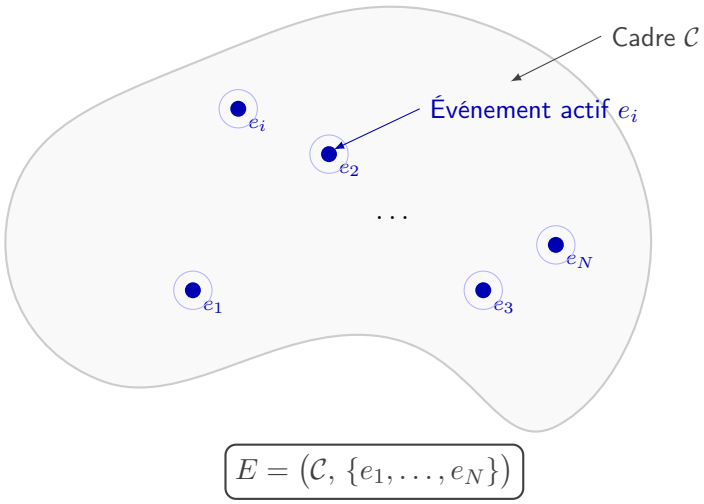


FIGURE 1 – Schématisation de l'environnement E

2.2 Axe temporel et dynamique

Définition 2.4 (Axe temporel)**.** *L'*axe temporel *est défini par*

$$\tau = \mathbb{R}^+.$$

Toutes les quantités du modèle sont donc considérées comme des fonctions du temps

$$t \in \tau.$$

Cependant, l'ensemble $\mathbb{R}^+$ *étant continu, sa représentation et son traitement informatique sont délicats en pratique. Afin de rendre le modèle exploitable numériquement, nous introduisons une discrétisation du temps en remplaçant* $\mathbb{R}^+$ *par un ensemble discret d'instants indexés :*

$$\tau_d = \mathbb{N}.$$

Le temps est ainsi représenté par une succession d'indices entiers correspondant aux instants d'observation ou de mise à jour du système.

Définition 2.5 (Environnement dynamique)**.** *[Contribution originale de l'auteur.]*

$$E : \tau \longrightarrow \mathscr{E}, \qquad t \longmapsto E(t) = \Big(\mathcal{C}(t),\ \{e_1, \ldots, e_{N(t)}\}\Big).$$

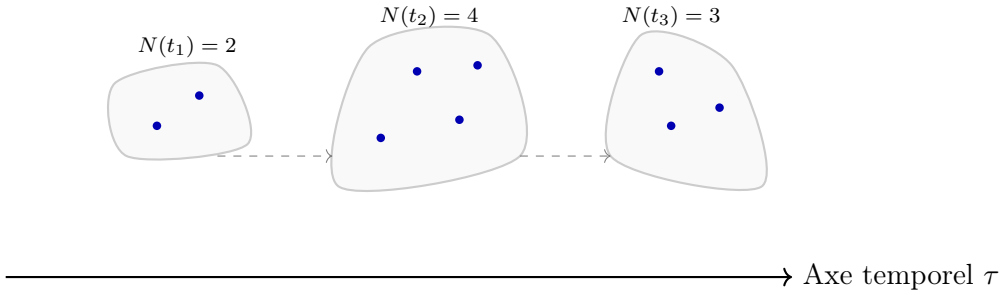


FIGURE 2 – Évolution dynamique de $E(t)$

Remarque 2.2. *$N(t)$ est supposée localement bornée sur tout compact $[0, T]$, garantissant que les sommes finies utilisées ultérieurement sont bien définies.*

Remarque 2.3 (Filtrage par ordre de grandeur)**.** *Dans une perspective d'implémentation réaliste, il n'est généralement pas possible de considérer exhaustivement l'ensemble des événements présents dans un environnement donné.*

En effet, un événement peut engendrer des conséquences qui deviennent elles-mêmes de nouveaux événements, lesquels produisent à leur tour d'autres effets. Cette propagation récursive conduit rapidement à une croissance combinatoire du nombre d'événements potentiellement observables.

Ainsi, d'un point de vue informatique, il devient nécessaire d'introduire un mécanisme de filtrage afin de limiter l'espace des événements effectivement pris en compte dans le modèle.

On associe alors à l'environnement un ordre de grandeur caractéristique noté h, ainsi qu'un ordre de grandeur propre h' à chaque événement. L'idée consiste à ne retenir que les événements dont l'échelle reste comparable à celle de l'environnement considéré.

Autrement dit, seuls les événements vérifiant une condition du type

$$h' \sim h$$

sont conservés dans l'analyse.

Ce choix se justifie naturellement :

- *les événements d'ordre de grandeur trop faible possèdent une influence négligeable sur la dynamique globale.*
- *inversement, les événements d'ordre de grandeur excessivement élevé relèvent souvent d'une dynamique extérieure au cadre étudié.*

Le filtrage par ordre de grandeur permet ainsi de conserver un modèle calculable, stable et cohérent avec l'échelle effective de l'environnement analysé.

Remarque 2.4 (Détermination pratique de h et h')**.** *Ce mécanisme de filtrage est une addition récente au cadre formel, et sa mise en œuvre pratique mérite d'être précisée. h n'est pas une quantité calculée de façon univoque par le modèle : au même titre que le cadre $\mathcal{C}$ (Définition 2.2), il s'agit d'un choix exogène, fixé par l'utilisateur en fonction de l'échelle à laquelle il souhaite étudier l'environnement (par exemple, une échelle « ville » exclura par construction des événements d'échelle « quartier » ou « pays »).*

En revanche, l'ordre de grandeur propre h' d'un événement peut, lui, être approché par un calcul simple à partir de ses attributs primaires, par exemple $h' \propto \mathcal{D} \cdot \mathcal{F} \cdot \mathcal{R}$, un proxy de son ampleur spatio-temporelle. Une fois h fixé par l'utilisateur, la condition $h' \sim h$ peut donc être évaluée automatiquement pour chaque événement candidat. Ce mécanisme reste, à ce stade, une heuristique de préfiltrage plutôt qu'une composante calibrée du modèle ; son automatisation complète (calcul de h lui-même à partir du cadre $\mathcal{C}$) est laissée en perspective (Section 9).

3 Caractérisation des événements

3.1 Les cinq attributs d'un événement

Symbole	Nom	Domaine	Description
$\mathcal{D}$	Durée	$\mathbb{R}^+$	Temps pendant lequel l'événement reste actif.
$\mathcal{F}$	Fréquence	$\mathbb{R}^+$	Nombre d'occurrences par unité de temps.
$\mathcal{R}$	Rayon d'action	$\mathbb{R}^+$	Étendue spatiale ou thématique de l'influence.
$\mathcal{G}$	Gravité	$\mathbb{R}$	Intensité de l'impact intrinsèque de l'événement.
$\mathcal{P}$	Prédictibilité	$\mathbb{R}^+$	Degré auquel l'événement peut être anticipé.

Remarque 3.1. *La gravité $\mathcal{G}$ peut être interprétée comme la résultante des quatre autres attributs.*

3.2 L'opérateur de caractérisation Γ

Définition 3.1 (Opérateur Ψ - forme générale)**.** *[Contribution originale de l'auteur.]*

Soit $\mathcal{A}$ l'espace des chaînes de caractères :

$$\Psi : \mathcal{A} \longrightarrow \mathbb{R}^5, \qquad e \longmapsto \big(\mathcal{D}, \mathcal{F}, \mathcal{R}, \mathcal{G}, \mathcal{P}\big). \tag{1}$$

Dans une implémentation pratique, Ψ peut être réalisé par un modèle de traitement du langage naturel. La définition mathématique reste indépendante de l'implémentation choisie.

L'opérateur Γ introduit ci-après (Définition 3.2) correspond à la restriction de Ψ au seul calcul de la gravité à partir des quatre attributs primaires.

Définition 3.2 (Opérateur Γ - forme réduite)**.** *Lorsque l'événement est représenté par ses quatre attributs primaires :*

$$\Gamma : \mathbb{R}^4 \longrightarrow \mathbb{R}, \qquad (\mathcal{D}, \mathcal{F}, \mathcal{R}, \mathcal{P}) \longmapsto \mathcal{G}. \tag{2}$$

Définition 3.3 (Forme fonctionnelle de Γ)**.** *[Contribution originale de l'auteur.]*

$$\mathcal{G} = \Gamma(\mathcal{D}, \mathcal{F}, \mathcal{R}, \mathcal{P}) = \frac{\mathcal{D}^{\alpha} \cdot \mathcal{F}^{\beta} \cdot \mathcal{R}^{\delta}}{1 + \mathcal{P}^{\gamma}}, \tag{3}$$

où $\alpha, \beta, \delta, \gamma > 0$ sont des paramètres à calibrer. La gravité croît avec la durée, la fréquence et le rayon d'action, et décroît avec la prédictibilité (les événements prévisibles peuvent être atténués en amont). Il s'agit d'un choix de modélisation ; les propriétés de monotonie et de décroissance qui en découlent sont établies en Annexe 9.4.

3.3 Intégration de la dynamique temporelle dans Γ

Définition 3.4 (Gravité résiduelle temporelle)**.** *[Contribution originale de l'auteur.]*

Soit un événement e apparaissant à t_0 avec une durée totale $\mathcal{D}$. Sa durée effective au temps t est $\mathcal{D}_{\text{eff}}(t) = \max(\mathcal{D} - (t - t_0), 0)$. La gravité temporellement dépendante est :

$$\mathcal{G}(t) = \Gamma\big(\mathcal{D}_{\text{eff}}(t), \mathcal{F}, \mathcal{R}, \mathcal{P}\big) = \frac{\big[\max(\mathcal{D} - (t - t_0), 0)\big]^{\alpha} \cdot \mathcal{F}^{\beta} \cdot \mathcal{R}^{\delta}}{1 + \mathcal{P}^{\gamma}}. \tag{4}$$

Remarque 3.2. *Dès $t \geq t_0 + \mathcal{D}$, la gravité s'annule exactement : l'événement n'influence plus l'état de santé. Cette formulation est cohérente avec l'adoption de poids statiques, puisque l'extinction temporelle de l'influence est entièrement pilotée par $\mathcal{D}_{\text{eff}}(t)$ dans Γ.*

3.4 Calibration des hyper-paramètres par cluster d'événements

3.4.1 Introduction

Un jeu unique de paramètres $(\alpha, \beta, \delta, \gamma)$ suppose une homogénéité structurelle de tous les événements. Or, en pratique, les événements se regroupent en familles aux *lois de gravité* distinctes.

Remarque 3.3 (Lois de gravité)**.** *Par* loi de gravité *d'une famille d'événements, on entend la relation fonctionnelle spécifique liant (D, F, R, P) à l'impact réel observé - entièrement caractérisée par le vecteur d'exposants $(\alpha, \beta, \delta, \gamma)$.*

Deux familles ont des lois différentes si leurs exposants optimaux diffèrent. Par exemple, pour un événement :

— Financier : la durée D tend à dominer (α élevé).
— Sanitaire : la fréquence F et le rayon R sont prépondérants (β, δ élevés).

Remarque 3.4 (Justification empirique de l'approche par cluster)**.** *L'argument théorique ci-dessus (hétérogénéité attendue des lois de gravité) motive le choix, adopté dès cette section et conservé tout au long de l'article, de calibrer Γ localement par cluster plutôt que globalement. Ce choix est également confirmé* a posteriori *par l'expérience : la comparaison quantitative entre un modèle global (jeu unique de paramètres) et un modèle par cluster, présentée en Section 7.4, montre un gain de précision systématique en faveur de la seconde approche. Le lecteur pressé de voir cette confirmation chiffrée peut s'y référer directement ; nous conservons ici l'ordre de présentation pédagogique (construction du modèle par cluster, puis validation) plutôt qu'une validation prématurée avant que tous les objets ne soient définis.*

Définition 3.5 (Partition en clusters)**.** *[Contribution originale de l'auteur.]*

Soit $\mathcal{B} = \{e_1, \ldots, e_N\}$ la base d'événements. Une partition en K clusters *est $\mathcal{B} = \mathcal{C}_1 \sqcup \cdots \sqcup \mathcal{C}_K$ telle que chaque $\mathcal{C}_k$ regroupe des événements de profil (D, F, R, P) similaires.*

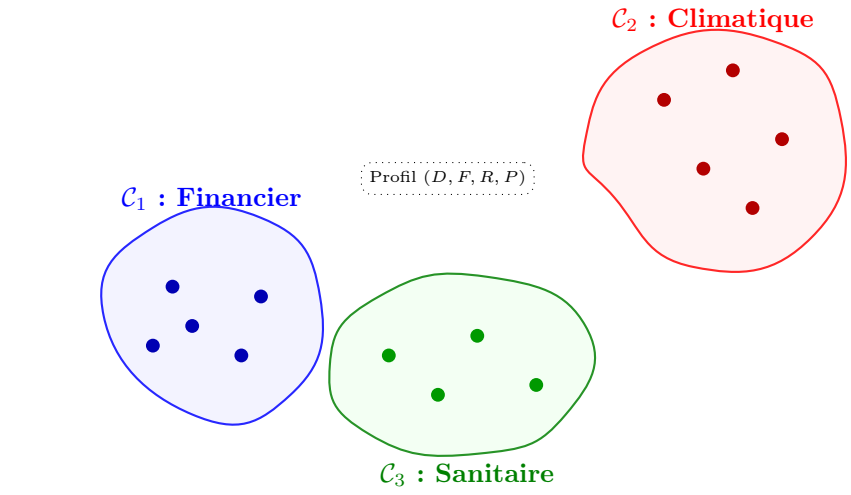


FIGURE 3 – Partition de $\mathcal{B}$ en clusters disjoints

Les formes patatoïdes représentent des régions de similarité dans l'espace des événements, au sein desquelles les paramètres $(\alpha_k, \beta_k, \delta_k, \gamma_k)$ sont calibrés indépendamment.

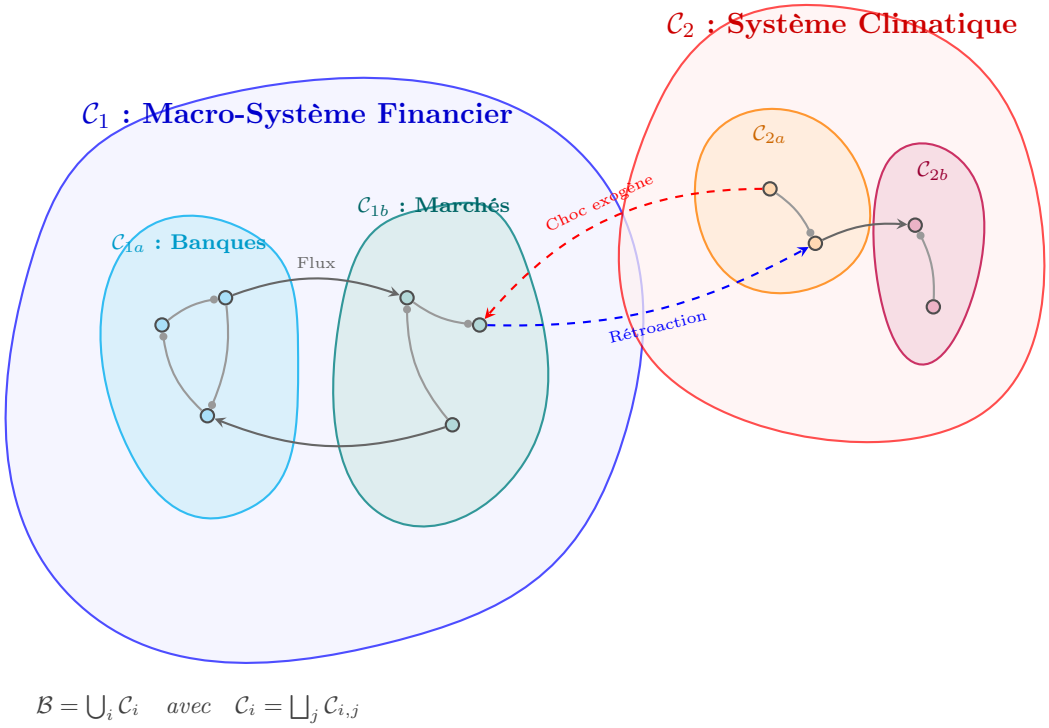


FIGURE 4 – Modélisation hiérarchique et synaptique de $\mathcal{B}$.

Les macro-clusters $(\mathcal{C}_1, \mathcal{C}_2)$ englobent des sous-structures spécialisées. Les nœuds y représentent des événements isolés (assimilables à des neurones), qui interagissent via des paramètres d'influence locale (synapses internes) et des chocs systémiques (axones inter-clusters).

En définitive, cette organisation en clusters s'avère essentielle pour la conception de notre modèle mathématique : elle permet de cibler des événements spécifiques et de catégoriser efficacement ceux présentant de fortes similarités.

Définition 3.6 (MAPE)**.** *[Résultat standard de la littérature.]*

La Mean Absolute Percentage Error *mesure l'écart relatif moyen :*

$$\mathrm{MAPE} = \frac{100}{n} \sum_{i=1}^{n} \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (\%). \tag{5}$$

Une MAPE de 0% *est la prédiction parfaite ; inférieure à* 5%*, elle est considérée comme très satisfaisante en modélisation de risques.*

Définition 3.7 (Calibration par cluster)**.** *[Contribution originale de l'auteur.]*

Pour chaque cluster $\mathcal{C}_k$*, on apprend* $\theta_k = (\alpha_k, \beta_k, \delta_k, \gamma_k)$ *en minimisant la MAPE :*

$$\hat{\theta}_k = \arg\min_{\theta \in \mathbb{R}^4_{>0}} \frac{1}{|\mathcal{C}_k|} \sum_{e_i \in \mathcal{C}_k} \frac{|\Gamma_\theta(e_i) - \mathcal{G}_i^{\mathrm{db}}|}{\mathcal{G}_i^{\mathrm{db}}}, \tag{6}$$

où $\mathcal{G}_i^{\mathrm{db}} \in \mathbb{R}^+$ *est la* gravité de référence *de* e_i*, issue d'une base historique ou d'une évaluation experte - l'impact réel observé* a posteriori*, par opposition à la gravité* prédite $\Gamma_\theta(e_i)$ *calculée* a priori*. Le couple* $(\hat{\theta}_k, k(i))$ *ainsi défini - le vecteur de paramètres du cluster, et l'indice du cluster contenant* e_i *- est réutilisé tel quel dans le reste de l'article ; nous le rappellerons brièvement à chaque nouvelle occurrence éloignée de cette définition.*

L'opérateur Γ *devient* localement adapté *:*

$$\Gamma(e_i) = \Gamma_{\hat{\theta}_{k(i)}}(e_i) \tag{7}$$

où $k(i)$ *désigne le cluster de* e_i*.*

Afin de prendre en compte l'hétérogénéité des événements présents dans la base de données, nous introduisons une formulation globale de l'opérateur Γ reposant sur une calibration locale par cluster.

L'idée consiste à associer à chaque cluster $\mathcal{C}_k$ un opérateur spécifique, calibré indépendamment sur les données appartenant à ce cluster. L'opérateur global est alors obtenu par agrégation de ces opérateurs locaux.

Définition 3.8 (Opérateur global par agrégation de clusters)**.** *Pour chaque cluster* $\mathcal{C}_k$*, on définit un opérateur local :*

$$\Gamma_k := \Gamma_{\hat{\theta}_k}, \tag{8}$$

où $\hat{\theta}_k$ *est obtenu par la procédure de calibration introduite dans la Définition 3.7.*

L'opérateur global Γ *s'écrit alors sous la forme :*

$$\Gamma(e_i) = \sum_{k=1}^{K} \mathbb{1}_{\{e_i \in \mathcal{C}_k\}} \Gamma_k(e_i), \tag{9}$$

où :

- K *désigne le nombre total de clusters.*
- $\mathbb{1}_{\{e_i \in \mathcal{C}_k\}}$ *est la fonction indicatrice valant* 1 *si* $e_i \in \mathcal{C}_k$*, et* 0 *sinon.*

Cette écriture revient à sélectionner l'opérateur local associé au cluster d'appartenance de l'événement e_i*. Ainsi, on obtient la forme équivalente :*

$$\Gamma(e_i) = \Gamma_{k(i)}(e_i), \tag{10}$$

où $k(i)$ *désigne l'indice du cluster contenant l'événement* e_i*.*

Remarque 3.5 (Avantages de la calibration par cluster)**.** *Cette approche présente plusieurs avantages importants :*

- *Flexibilité : chaque cluster possède ses propres paramètres* $\hat{\theta}_k = (\alpha_k, \beta_k, \delta_k, \gamma_k)$*, ce qui permet d'adapter localement le comportement de l'opérateur* Γ *aux caractéristiques spécifiques de chaque famille d'événements.*
- *Interprétabilité : les paramètres appris conservent une signification physique ou empirique. Par exemple, une valeur élevée de* α_k *traduit une forte influence de la durée dans l'évaluation de la gravité des événements du cluster considéré.*
- *Robustesse : la séparation en clusters limite l'influence des comportements atypiques entre catégories d'événements différentes, ce qui améliore la stabilité globale de la calibration.*
- *Extensibilité : l'ajout d'un nouveau type d'événement ne nécessite pas de réentraîner l'ensemble du modèle global. Il suffit d'apprendre un nouveau jeu de paramètres* $\hat{\theta}_{K+1}$ *associé au cluster correspondant.*
- *Modularité : chaque opérateur local* Γ_k *peut être étudié, modifié ou amélioré indépendamment des autres clusters, ce qui facilite les mises à jour futures du modèle.*
- *Meilleure précision locale : certaines familles d'événements présentent des dynamiques très différentes. Une calibration spécifique par cluster permet donc d'obtenir une meilleure approximation locale qu'un unique modèle global.*

3.5 Construction lexicale des clusters

3.5.1 Introduction

Nous avons étudié la manière dont l'introduction de clusters pouvait améliorer notre modèle. Toutefois, nous ne nous sommes pas encore intéressés à la manière de construire ces clusters. Pour cela, nous proposons une approche lexicale, dans laquelle les événements sont regroupés selon les mots-clés qu'ils partagent.

3.5.2 Développement

L'idée générale est que deux événements possédant un vocabulaire similaire seront considérés comme proches dans l'espace de représentation.

Considérons l'événement suivant :

> *« Un feu de grande ampleur s'est déclenché dans l'Amazonie lors d'une sécheresse. »*

Dans cette description, les termes *feu* et *Amazonie* permettent d'associer l'événement à la catégorie des *feux de forêt*. Le terme *sécheresse* peut, quant à lui, être interprété comme un événement secondaire ou un facteur aggravant indépendant.

Enfin, l'expression *de grande ampleur* correspond davantage à une caractérisation quantitative de l'événement qu'à une catégorie lexicale ; cette intensité sera donc prise en compte directement par notre modèle de gravité.

Proposition 3.1 (Clustering lexical des événements)**.** *[Contribution originale de l'auteur.]*

Soit un événement e_i décrit par un ensemble de mots-clés :

$$e_i = \{w_{i1}, w_{i2}, \ldots, w_{in}\}. \tag{11}$$

La proximité entre deux événements e_i et e_j peut être évaluée par une mesure de similarité lexicale définie par :

$$\mathrm{Sim}(e_i, e_j) = \frac{|e_i \cap e_j|}{|e_i \cup e_j|}. \tag{12}$$

Deux événements sont alors associés à un même cluster lexical lorsque leur similarité dépasse un seuil fixé :

$$\mathrm{Sim}(e_i, e_j) \geq \tau, \tag{13}$$

où $\tau \in [0, 1]$ désigne le seuil de regroupement.

Cette méthode génère automatiquement des catégories d'événements fondées sur leurs similarités lexicales, tout en garantissant des regroupements (clusters) dont l'interprétation reste intuitive.

Il devient ainsi possible d'affiner progressivement la granularité de la classification, afin de créer des sous-familles d'événements de plus en plus spécifiques et ciblées.

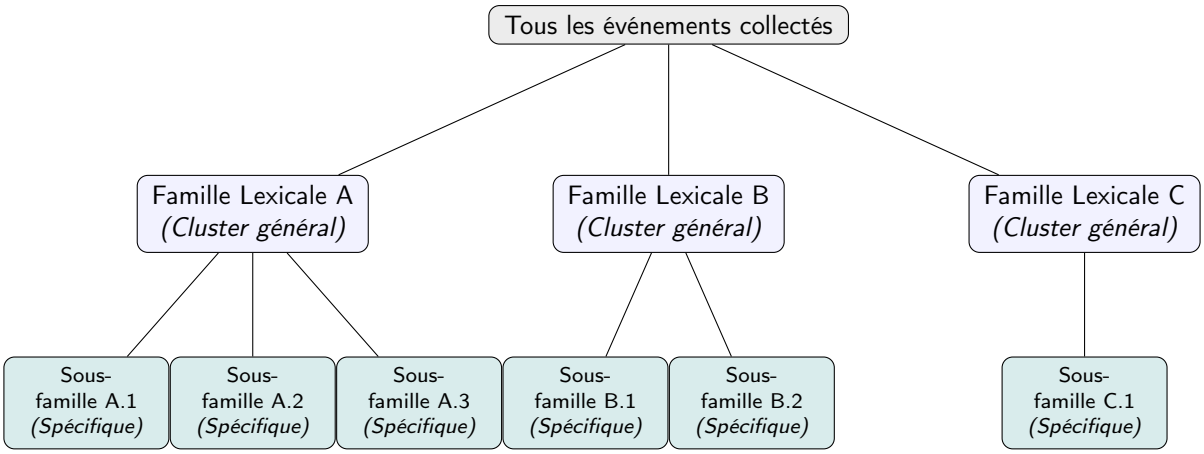


FIGURE 5 – Regroupement d'événements en sous-familles successives

3.6 Reformulation de l'environnement dynamique

On substitue chaque événement par son image sous Γ avec les paramètres calibrés $\hat{\theta}_{k(i)}$ de la Définition 3.7 :

$$E(t) = \Big(\mathcal{C}(t),\ \big\{\Gamma_{\hat{\theta}_{k(1)}}(e_1), \Gamma_{\hat{\theta}_{k(2)}}(e_2), \ldots, \Gamma_{\hat{\theta}_{k(N(t))}}(e_{N(t)})\big\}\Big), \qquad \forall\, t \in \tau. \tag{14}$$

Remarque 3.6. *L'indice $\hat{\theta}_{k(i)}$ dans (14) est essentiel : il signifie que chaque événement est caractérisé par les paramètres de son propre cluster, et non par un jeu global. Cette dépendance en θ_k est une contribution originale de ce travail.*

4 Interactions entre événements

4.1 Types d'interactions

Définition 4.1 (Types d'interactions)**.** *[Contribution originale de l'auteur.]*

Soient e_i et e_j deux événements coexistants. On distingue :

- *Amplification : e_j renforce l'impact de e_i (ex : sécheresse → feu).*
- *Rétroaction : e_i et e_j s'entretiennent mutuellement.*
- *Neutralisation : e_j atténue l'impact de e_i (ex : intervention préventive → catastrophe naturelle).*

4.2 Matrice d'interaction

Définition 4.2 (Matrice d'interaction)**.** *[Contribution originale de l'auteur.]*

La matrice d'interaction $\mathbf{W}(t) \in \mathbb{R}^{N(t)\times N(t)}$ *encode le type d'interaction (Définition 4.1) de e_j sur e_i :*

- *$W_{ij}(t) > 0$: amplification ou rétroaction - e_j renforce e_i.*
- *$W_{ij}(t) < 0$: neutralisation - e_j atténue e_i.*
- *$W_{ij}(t) = 0$: absence d'interaction entre e_i et e_j.*

Remarque 4.1 (Distinction amplification / rétroaction)**.** *Le signe de $W_{ij}(t)$ seul ne permet pas de distinguer une simple amplification d'une véritable rétroaction (Définition 4.1).*

On propose de formaliser cette distinction ainsi :

- *L'interaction de e_j sur e_i est une* amplification simple *lorsque $W_{ij}(t) > 0$ et $W_{ji}(t) = 0$ (influence à sens unique).*
- *L'interaction de e_j sur e_i est une* rétroaction *lorsque $W_{ij}(t)\,W_{ji}(t) > 0$ (les deux événements s'entretiennent mutuellement).*

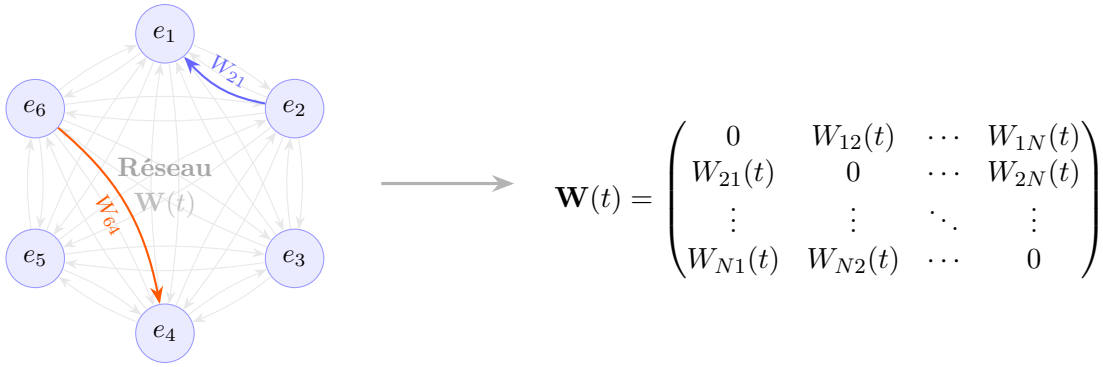


FIGURE 6 – Correspondance entre réseau d'interactions et représentation matricielle

Comme nous avons introduit la notion d'influence, la gravité ne peut plus être simplement calculée à partir de ses seuls paramètres locaux, mais doit également prendre en compte ceux des événements voisins.

C'est pourquoi nous introduisons une nouvelle forme de la loi de gravité, intégrant les interactions entre événements.

Définition 4.3 (Gravité effective). *[Contribution originale de l'auteur.]*

$$\widetilde{\mathcal{G}}_i(t) = \mathcal{G}_i(t) + \sum_{\substack{j=1 \\ j \neq i}}^{N(t)} W_{ij}(t)\, \mathcal{G}_j(t). \tag{15}$$

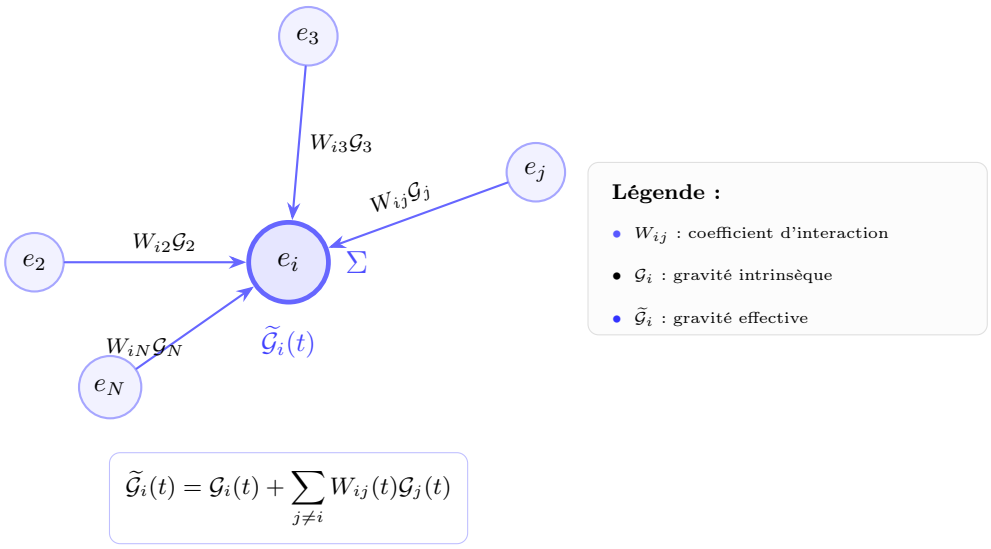


FIGURE 7 – Calcul de $\widetilde{\mathcal{G}}_i$

Dans un but d'implémentation, les formulations vectorielles et matricielles sont privilégiées, celles-ci étant à la fois plus simples à manipuler et plus efficaces que des boucles explicites en Python.

Nous traduisons donc la forme additive de la gravité en une écriture matricielle compacte.

Proposition 4.1 (Forme vectorielle de la gravité effective). *[3]*

On définit la gravité effective par :

$$\widetilde{\mathbf{G}}(t) = \big(\mathbf{I} + \mathbf{W}(t)\big)\mathbf{G}(t).$$

En posant la matrice d'influence augmentée :

$$\mathbf{W}^{\star}(t) := \mathbf{I} + \mathbf{W}(t),$$

on obtient une écriture équivalente plus compacte :

$$\widetilde{\mathbf{G}}(t) = \mathbf{W}^{\star}(t)\mathbf{G}(t),$$

où $\mathbf{W}^{\star}(t)$ intègre directement les effets propres (diagonale) et les interactions entre événements (hors-diagonale).

Démonstration. Voir Annexe 9.4. □

5 Cadre algorithmique

Algorithm 1 Calcul de $\zeta_\lambda(E(t))$

Entrée : $\{e_i\}$, $\mathbf{W}(t)$, $\{\omega_i\}$, $\lambda > 0$.
Étape 1 - Gravités :
for $i = 1$ **to** $N(t)$ **do**
  $\mathcal{G}_i(t) \leftarrow \Gamma_{\hat{\theta}_{k(i)}}(\mathcal{D}_{\text{eff},i}(t), \mathcal{F}_i, \mathcal{R}_i, \mathcal{P}_i)$ [éq. (4)]
end for
Étape 2 - Gravités effectives :
$\widetilde{\mathbf{G}}(t) \leftarrow \mathbf{W}^\star(t)\mathbf{G}(t)$
Étape 3 - Agrégation avec poids statiques normalisés :
$\bar{\omega}_i \leftarrow \omega_i / \sum_j |\omega_j|$
$S(t) \leftarrow \sum_i \bar{\omega}_i \widetilde{\mathcal{G}}_i(t)$
Étape 4 - Normalisation :
$\zeta_\lambda(E(t)) \leftarrow \tanh(S(t)/\lambda)$
Sortie : $\zeta_\lambda(E(t)) \in (-1, 1)$

Remarque 5.1. *Complexité dominée par l'Étape 2 : $O(N(t)^2)$ en implémentation naïve.*

6 L'état de santé d'un environnement

6.1 Introduction

Cette section aborde le cœur de la contribution de l'article. Pour rappel, l'objectif est de construire une quantité mesurable permettant d'évaluer si l'environnement est propice, ou non, à l'évolution de l'utilisateur.

L'ensemble des développements précédents (allant de la traduction mathématique de l'environnement via ses éléments fondamentaux (les événements, Section 3) jusqu'à la modélisation de la complexité de leurs interactions (Section 4)) constitue une base solide pour définir cette quantification.

Cette grandeur sera appelée ***état de santé***.

6.2 Motivation et définition

Définition 6.1 (État de santé)**.** *[Contribution originale de l'auteur.]*

*L'*état de santé $\zeta(E(t)) \in (-1, 1)$ *est une fonction scalaire qui quantifie, à chaque instant t, la propension globale de l'environnement $E(t)$ à induire une évolution positive ou négative de l'utilisateur.*

Cette grandeur est normalisée dans l'intervalle $(-1, 1)$ afin de garantir une interprétation uniforme, indépendante de l'échelle des événements considérés. Cette normalisation peut être interprétée comme une généralisation de la notion de pourcentage, où -1 correspond à une situation entièrement défavorable (-100 %) et $+1$ à une situation entièrement favorable (+100 %).

Plus précisément :

- *lorsque $\zeta(E(t)) \to +1$, l'environnement est fortement favorable, et les dynamiques observées contribuent majoritairement à une amélioration de l'état de l'utilisateur ;*
- *lorsque $\zeta(E(t)) \to -1$, l'environnement est fortement défavorable, traduisant une accumulation d'événements négatifs ou dégradants ;*
- *lorsque $\zeta(E(t)) \approx 0$, l'environnement est neutre, les effets positifs et négatifs se compensant globalement.*

Ainsi, $\zeta(E(t))$ fournit une synthèse normalisée de l'impact global de l'environnement sur l'utilisateur.

Remarque 6.1. *Bien sûr, cette notion d'évolution dépend intrinsèquement de l'utilisateur considéré. Un environnement peut être hostile pour un individu donné, tout en étant globalement favorable pour un autre.*

Nous nous appuyons ici sur l'idée d'un équilibre entre le « bien » et le « mal », concept largement évoqué dans divers domaines, notamment les écrits religieux, économiques et philosophiques.

6.3 L'opérateur ζ

Définition 6.2 (Opérateur ζ)**.** *[Contribution originale de l'auteur.]*

L'opérateur ζ est défini par l'application :

$$\zeta : \mathscr{E} \longrightarrow (-1, 1), \qquad E \longmapsto \zeta(E).$$

Évalué à un instant t, l'opérateur s'exprime par la fonction :

$$\zeta(E(t)) = \tanh(S(t)) = \tanh\left(\sum_{i=1}^{N_{\text{événements}}(t)} \text{poids}_i \, \text{GravitéEffective}_i \right)$$

Intervalle	Nature	Interprétation
$(-1, 0)$	Négative	Dégradation selon le point de vue de l'utilisateur.
$\{0\}$	Neutre	Équilibre ; aucun changement net.
$(0, 1)$	Positive	Amélioration selon le point de vue de l'utilisateur.

6.4 Choix de tanh et propriétés associées

La fonction tanh est utilisée comme fonction de normalisation centrale de notre modèle afin de transformer une grandeur non bornée $S(t) \in \mathbb{R}$ en un indicateur borné $\zeta(t) \in (-1, 1)$, interprétable comme un état de santé.

Proposition 6.1 (Propriétés fondamentales de tanh)**.** *[Résultat standard de la littérature.]*

[2] La fonction $\tanh : \mathbb{R} \to (-1, 1)$ *est une bijection strictement croissante vérifiant les propriétés suivantes :*

- $\zeta(t) \in (-1, 1)$ *pour toute valeur finie de* $S(t)$ *;*
- *la transformation préserve le signe :* $\text{sign}(\tanh(S)) = \text{sign}(S)$ *;*
- *il n'y a pas de perte d'information structurelle,* tanh *étant injective et monotone ;*
- *la saturation en* ± 1 *permet une interprétation bornée et stable des extrêmes.*

Démonstration. Voir Annexe 9.4. □

La propriété clé de tanh réside dans sa *saturation progressive*. En effet,

$$\tanh'(x) = 1 - \tanh^2(x) \longrightarrow 0 \quad \text{lorsque } |x| \to +\infty.$$

Ainsi, atteindre les valeurs limites ± 1 supposerait un environnement *absolument* favorable ou défavorable, ce qui n'est pas réaliste dans les systèmes complexes étudiés ici. La fonction tanh formalise ainsi un *principe d'impossibilité des extrêmes absolus*.

Enfin, la *linéarité locale* au voisinage de l'origine joue un rôle fondamental :

$$\tanh(S) \approx S - \frac{S^3}{3} + \mathcal{O}(S^5).$$

Cette propriété garantit que les situations ordinaires ($S \approx 0$) ne subissent aucune distorsion artificielle, tout en assurant une transition progressive vers les régimes extrêmes.

6.5 Poids statiques et normalisation L^1

6.5.1 Introduction

La décroissance temporelle de l'influence d'un événement est entièrement régie par le terme $\mathcal{D}_{\text{eff}}(t)$ au sein de l'opérateur Γ (Section 3.3), via une fonction exponentielle contrôlée par l'hyperparamètre α.

Dans ce contexte, il n'est pas nécessaire que les poids associés aux événements soient dynamiques, puisque la durée effective intègre déjà cette dimension temporelle. Ils sont donc considérés comme *structurellement statiques* : ils ne varient pas explicitement en fonction du temps, mais dépendent implicitement de l'état courant du système.

6.5.2 Définition et interprétation des poids

Définition 6.3 (Poids initial)**.** *[Contribution originale de l'auteur.]*

À chaque événement e_i est associé un poids $\omega_i \in [-\omega_{\max}, \omega_{\max}]$, représentant son influence intrinsèque sur la dynamique de l'environnement, selon la convention suivante :

- *$\omega_i > 0$: contribution favorable, améliorant l'état global ;*
- *$\omega_i < 0$: contribution défavorable, dégradant l'état global ;*
- *$|\omega_i|$: intensité de l'influence, indépendamment de son signe ;*
- *$\omega_i = 0$: événement neutre, sans impact direct.*

Ainsi, ω_i encode à la fois la nature et l'amplitude de l'effet de chaque événement sur l'état de santé.

6.5.3 Normalisation L^1 et propriétés

Définition 6.4 (Poids normalisés)**.** *[Contribution originale de l'auteur.]*

$$\bar{\omega}_i = \frac{\omega_i}{\sum_{j=1}^{N(t)} |\omega_j|} \quad \textit{de sorte que} \quad \sum_{i=1}^{N(t)} |\bar{\omega}_i| = 1. \tag{16}$$

Proposition 6.2 (Propriétés de la normalisation L^1)**.** *[Contribution originale de l'auteur.]*

La normalisation (16) confère à l'opérateur ζ les propriétés suivantes :

(i) Invariance à l'échelle : pour tout $c > 0$, remplacer ω_i par $c\,\omega_i$ pour tout i ne modifie pas ζ. Seule la structure relative des contributions est prise en compte.

(ii) Stabilité à l'ajout d'un événement neutre : l'introduction d'un événement de poids nul ne modifie pas la valeur de $S(t)$.

(iii) Borne de contrôle : $|S(t)| \leq \max_i |\widetilde{\mathcal{G}}_i(t)|$, ce qui garantit que la normalisation n'amplifie pas artificiellement les contributions individuelles.

6.6 Construction d'un drap de poids par minimisation variationnelle

6.6.1 Introduction

L'objectif est de prédire le poids ω d'un nouvel événement à partir de sa position dans l'espace des attributs. Nous construisons à cet effet une surface continue (le *drap de poids*) interpolant les observations et vérifiant une hypothèse de régularité géométrique.

6.6.2 Hypothèse de régularité

Définition 6.5 (Régularité du drap)**.** *[Contribution originale de l'auteur.]*

Deux événements de profils proches dans $\mathbb{R}^4$ doivent avoir des poids proches. Il serait incohérent qu'un événement ait un poids proche de -14 alors que tous ses voisins ont des poids proches de 2. Nous cherchons donc la surface la plus « plate » possible, compatible avec les données observées.

6.6.3 Rugosité locale et mesure des variations

Pour simplifier l'exposition et permettre une illustration en trois dimensions, nous nous plaçons dans le cas de deux variables (x, y), représentant deux des quatre attributs primaires.

Définition 6.6 (Rugosité locale)**.** *La* rugosité locale *de f en (x, y) est :*

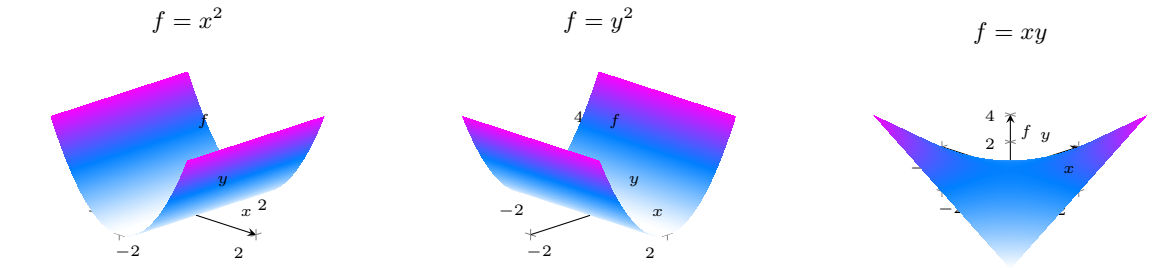
$$c(f)(x, y) = \left(\frac{\partial f}{\partial x}\right)^2 + \left(\frac{\partial f}{\partial y}\right)^2. \tag{17}$$

Elle est nulle si et seulement si f est localement constante. Une surface parfaitement plate vérifie $c(f) \equiv 0$.

Définition 6.7 (Régimes de rugosité)**.** *Selon la direction dans laquelle f varie, on distingue :*

- *Rugosité selon x uniquement : $\partial f/\partial x$ ne dépend pas de y, mais $\partial f/\partial y$ varie. Forme typique : $f(x, y) = H(x) + G(y)$ avec G non constante.*
- *Rugosité selon y uniquement : rôles de x et y échangés.*
- *Rugosité selon x et y : variations des dérivées partielles dans les deux directions (cas général, forme typique : $f(x, y) = xy$).*

Les trois figures suivantes illustrent chacun de ces régimes.



(a) Rugosité selon x : $\partial f/\partial y = 0$. (b) Rugosité selon y : $\partial f/\partial x = 0$. (c) Rugosité croisée : variations dans les deux directions.

FIGURE 8 – Trois régimes de rugosité locale.

- **(a)** $f = x^2$: rugosité selon x uniquement, surface constante le long de y.
- **(b)** $f = y^2$: cas symétrique, surface constante le long de x.
- **(c)** $f = xy$: rugosité croisée (surface en selle), cas général où les dérivées partielles varient dans toutes les directions.

6.6.4 Utilité de la rugosité locale $c(f)$

L'inspection visuelle d'une surface f ne suffit pas toujours à identifier ses zones de forte variation.

La rugosité locale $c(f)$ agit ici comme un *indicateur d'instabilité* : elle met en évidence, de manière immédiate, les régions où la fonction varie rapidement, même lorsque ces variations restent invisibles à l'œil nu.

6.6.5 Illustration de la rugosité locale sur deux cas représentatifs

Pour illustrer le rôle de la rugosité locale comme indicateur d'instabilité, on considère deux fonctions définies sur le domaine $x + y > 0$:

$$f_1(x, y) = \frac{1}{x + y} \quad \text{et} \quad f_2(x, y) = \frac{1}{x + y} + x.$$

Le premier cas met en évidence une singularité pure, tandis que le second introduit une perturbation globale linéaire. L'objectif est d'observer la robustesse de la rugosité locale face à ces deux types de comportements.

Cas 1 — Fonction singulière.

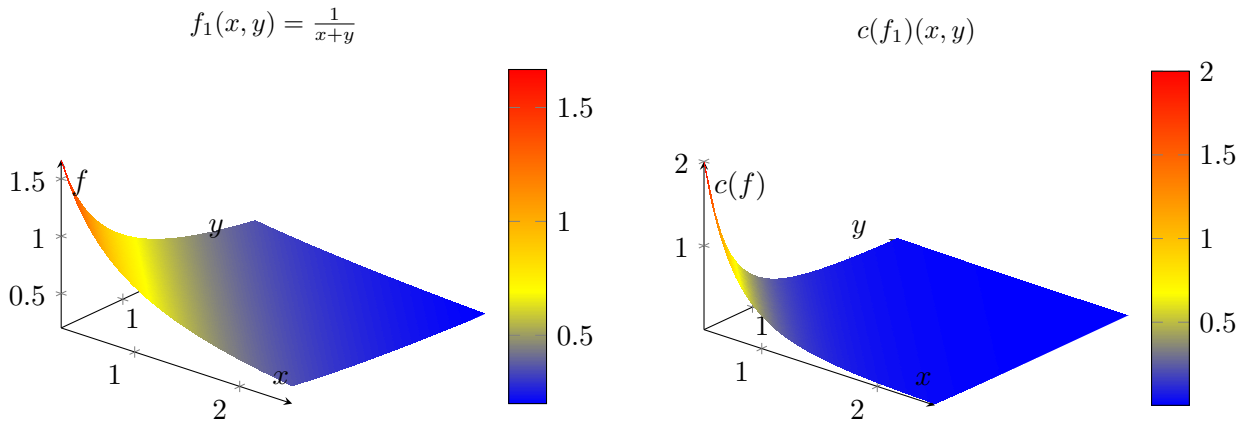


FIGURE 9 – Surface f_1 et rugosité locale associée.

La fonction f_1 présente une apparente régularité sur une large partie du domaine. Toutefois, la rugosité locale

$$c(f_1)(x,y) = \frac{2}{(x+y)^4}$$

révèle une instabilité fortement concentrée lorsque $x+y \to 0^+$. On observe ainsi que les variations critiques ne sont pas directement visibles sur la surface elle-même.

Cas 2 — Fonction perturbée.

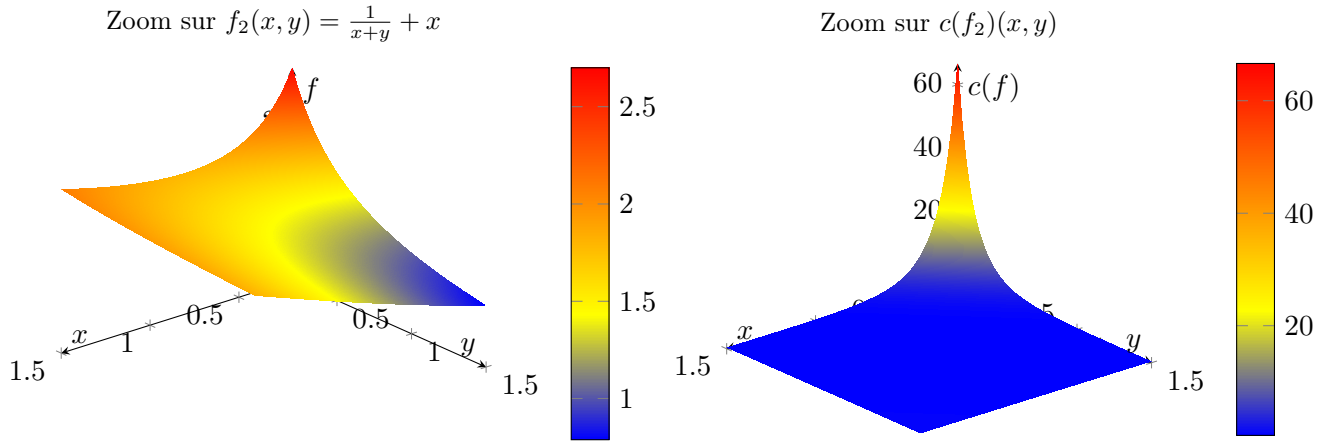


FIGURE 10 – Zoom local sur f_2 et sa rugosité locale $c(f_2)$.

L'ajout du terme x induit une tendance globale sans supprimer la singularité principale. La rugosité locale devient :

$$c(f_2)(x,y) = \left(-\frac{1}{(x+y)^2} + 1\right)^2 + \left(-\frac{1}{(x+y)^2}\right)^2.$$

On observe alors deux contributions distinctes :

— une dérive globale liée au terme x ;
— une singularité persistante identique au cas 1 ;
— une séparation nette entre structure globale et instabilités locales.

Conclusion. La rugosité locale $c(f)$ est robuste aux transformations globalement lisses et met systématiquement en évidence les zones d'instabilité structurelle.

6.6.6 Fonctionnelle d'énergie et drap optimal

Définition 6.8 (Energie de variation)**.** *[Contribution originale de l'auteur.]*

La fonctionnelle d'énergie *de f sur un domaine $\Omega \subset \mathbb{R}^2$ est :*

$$I(f) = \iint_{\Omega} \left[\left(\frac{\partial f}{\partial x} \right)^2 + \left(\frac{\partial f}{\partial y} \right)^2 \right] dx\, dy. \tag{18}$$

Le drap optimal *est $f^* = \arg\min I(f)$ sous la contrainte d'interpoler les poids observés $\{(\mathbf{x}_j, \omega_j)\}_{j \in \mathcal{C}_k}$.*

Remarque 6.2 (Évaluation numérique de $I(f)$)**.** *En pratique, l'intégrale (18) est évaluée par quadrature numérique sur la grille discrète τ_d introduite en Section 2.2, à partir des positions $\{\mathbf{x}_j\}$ des événements observés dans le cluster $\mathcal{C}_k$ (par exemple par différences finies sur ces points), plutôt que calculée analytiquement.*

Proposition 6.3 (Rugosité uniaxiale avec composante affine)**.** *On considère une fonction de la forme séparée :*

$$f(x, y) = H(x) + G(y),$$

où l'une des deux composantes est affine. Sans perte de généralité, on suppose que :

$$H(x) = ax + b, \qquad a, b \in \mathbb{R},$$

tandis que G est une fonction non linéaire suffisamment régulière. Comme $H'(x) = a$ est indépendant de b (l'énergie de variation est invariante par translation verticale), la fonctionnelle de régularité se décompose en :

$$I(f) = L_y \int_0^{L_x} a^2\, dx + L_x \int_0^{L_y} [G'(y)]^2\, dy = L_y L_x a^2 + L_x \int_0^{L_y} [G'(y)]^2\, dy \tag{19}$$

Démonstration. $\partial f/\partial x = H'(x)$ et $\partial f/\partial y = G'(y)$. L'intégration sur $[0, L_x] \times [0, L_y]$ donne directement (19). □

6.6.7 Normalisation par la taille du domaine

L'énergie $I(f)$ croît mécaniquement avec les dimensions du domaine. Pour comparer des clusters de tailles différentes, on normalise par les diamètres.

Définition 6.9 (Fonctionnelle normalisée)**.** *[Contribution originale de l'auteur.]*

$$\bar{I}(f) = \frac{1}{L_x L_y}\, I(f), \tag{20}$$

où L_x (resp. L_y) est la plus grande distance entre deux points du cluster selon l'axe x (resp. y).

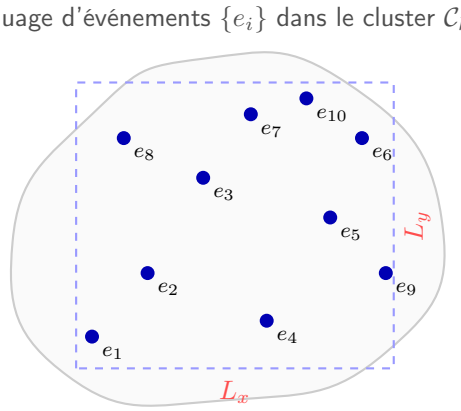


FIGURE 11 – Nuage d'événements e_i organisé dans un domaine spatial $\mathcal{C}_k$, délimité par une boîte englobante caractérisée par L_x et L_y.

Remarque 6.3. *Dans le cas séparable $f = H(x) + G(y)$, la normalisation donne :*

$$\bar{I}(f) = \frac{1}{L_x}\int_0^{L_x} [H'(x)]^2\,dx + \frac{1}{L_y}\int_0^{L_y} [G'(y)]^2\,dy,$$

soit l'énergie de déformation par unité de longueur selon chaque axe — une quantité intrinsèque au cluster, indépendante de son volume.

6.6.8 Forme paramétrique par défaut et prédiction

Une fois le problème variationnel posé, se pose la question pratique de la *forme* de f à optimiser. Chercher f^* sans contrainte de forme dans l'ensemble de toutes les fonctions différentiables reviendrait à chercher une aiguille dans une botte de foin : l'espace des candidats est trop vaste pour être exploré directement.

Nous proposons donc une famille paramétrique par défaut, suffisamment flexible pour s'adapter aux données tout en restant régulière. La forme retenue est une combinaison affine des attributs augmentée d'un terme d'interaction :

Définition 6.10 (Forme paramétrique polynomiale du drap)**.** *[Contribution originale de l'auteur.]*

Sur le cluster $\mathcal{C}_k$ projeté sur deux attributs (x, y), on considère la famille de polynômes de degré total n :

$$f_{\mathbf{a}}^{(n)}(x,y) = \sum_{\substack{i,j\geq 0\\ i+j\leq n}} a_{ij}\,x^i y^j, \tag{21}$$

où les coefficients $\mathbf{a} = \{a_{ij}\}$ sont calibrés par minimisation de $\bar{I}(f_{\mathbf{a}}^{(n)})$ sous contrainte d'interpolation des poids observés. Le nombre de paramètres est $\binom{n+2}{2} = \frac{(n+1)(n+2)}{2}$, croissant quadratiquement avec n. (Ces coefficients sont notés a_{ij}, et non λ_{ij}, précisément pour ne pas entrer en conflit avec le paramètre de dilatation λ introduit plus loin, en Section 7.2.)

Remarque 6.4 (Hiérarchie des degrés)**.** *Les premiers niveaux de la famille (21) sont :*

- *$n = 1$: plan affine $a_{00} + a_{10}x + a_{01}y$ (3 paramètres) - aucune interaction entre attributs ;*
- *$n = 2$: quadratique complet (6 paramètres) - couvre les trois régimes de rugosité ;*
- *$n = 3$: cubique (10 paramètres) - capture les courbures locales ;*
- *$n \to \infty$: convergence vers le drap optimal f^* au sens variationnel.*

La précision d'interpolation s'améliore avec n, au prix d'un risque de sur-ajustement croissant pour les clusters de petite taille.

Proposition 6.4 (Convergence de la précision avec n)**.** *[Contribution originale de l'auteur.]*

Soit RMSE(n) *l'erreur quadratique moyenne de prédiction des poids sur un ensemble de validation, associée à $f_{\hat{\mathbf{a}}}^{(n)}$ calibrée par moindres carrés. Sous l'hypothèse que les poids vrais sont issus d'une fonction régulière sur Ω,* RMSE(n) *est décroissante en n. Le degré optimal n^* est défini par :*

$$n^* = \arg\min_n \Big[\mathrm{RMSE}(n) + \mu \, \frac{\binom{n+2}{2}}{m} \Big], \tag{22}$$

où $m = |\mathcal{C}_k|$ est la taille du cluster et $\mu > 0$ un facteur de régularisation qui pénalise la complexité relative du modèle.

Remarque 6.5 (Lecture intuitive du critère (22))**.** *Intuitivement, ce critère traduit un compromis biais-variance classique : augmenter n réduit toujours l'erreur d'ajustement* sur les points déjà observés *(le drap colle de mieux en mieux aux données d'entraînement), mais chaque paramètre supplémentaire consomme une part de l'information disponible dans un cluster de taille finie m. Le terme $\mu\binom{n+2}{2}/m$ pénalise donc les degrés élevés proportionnellement au* nombre de paramètres par point de donnée disponible *: pour un petit cluster, même un léger gain de RMSE ne suffit pas à justifier un degré élevé, tandis qu'un grand cluster peut se permettre davantage de paramètres sans risque de sur-ajustement. Concrètement, n^* est le plus petit degré au-delà duquel le gain de précision ne compense plus, en pratique, le coût - en paramètres - de cette précision. Le Tableau 2 (Section 6.9.2) en donne une illustration numérique directe : le RMSE d'entraînement continue de baisser avec n, tandis que le RMSE de validation stagne, voire empire.*

6.7 Critère d'asymétrie

Définition 6.11 (Erreurs de prédiction)**.** *On distingue deux types d'erreurs dans l'estimation des interactions :*

- *Sous-estimation (type I) : $\hat{\mathcal{G}}_i < \mathcal{G}_i^{\mathrm{db}}$, correspondant à une sous-évaluation de l'intensité réelle de l'événement ;*
- *Sur-estimation (type II) : $\hat{\mathcal{G}}_i > \mathcal{G}_i^{\mathrm{db}}$, correspondant à une surestimation de cette même intensité.*

La sous-estimation est généralement plus critique que la sur-estimation, car elle peut conduire à des pertes irréversibles, tandis que la sur-estimation induit principalement un coût d'opportunité.

Cette asymétrie justifie l'introduction d'une fonction de perte non symétrique, définie par :

$$\ell(\hat{g}, g) = \begin{cases} c_+ \, (\hat{g} - g)^2 & \text{si } \hat{g} \geq g, \\ c_- \, (\hat{g} - g)^2 & \text{si } \hat{g} < g, \end{cases} \tag{23}$$

où les coefficients c_- et c_+ pondèrent respectivement la sévérité des erreurs de sous-estimation et de sur-estimation, avec $c_- > c_+$ dans le cas des événements à fort impact négatif.

La définition de ces poids est laissée à la discrétion de l'utilisateur, afin de s'adapter aux spécificités du contexte d'application.

Remarque 6.6 (Fixation pratique de c_- et c_+)**.** *À défaut d'un choix motivé par le contexte, une valeur par défaut raisonnable est $c_+ = 1$ et $c_- \in [1{,}5,\ 3]$: le rapport c_-/c_+ joue alors le rôle d'un coefficient d'aversion au risque, d'autant plus élevé que l'on souhaite pénaliser fortement toute sous-estimation de la gravité. Ce rapport peut également être calibré empiriquement, en*

confrontant la fonction de perte (23) à un panel d'événements historiques dont le coût réel d'une sous-estimation est connu (pertes financières observées, dégâts constatés), et en choisissant c_-/c_+ de façon à minimiser un coût opérationnel plutôt qu'une simple erreur quadratique. En l'absence d'un tel panel, le choix reste, comme indiqué, à la discrétion de l'utilisateur - au même titre que le cadre $\mathcal{C}$ ou les poids initiaux ω_i (Section 6.5).

Remarque 6.7 (Articulation avec la calibration par cluster)**.** *La procédure de calibration par cluster décrite à la Définition 3.7 minimise, dans sa formulation actuelle, la MAPE symétrique (5).*

Le critère d'asymétrie $\ell(\hat{g}, g)$ introduit ci-dessus constitue une fonction objectif alternative, particulièrement pertinente pour les clusters associés à des événements à fort impact négatif (par exemple $\mathcal{C}_2$ ou $\mathcal{C}_3$) : substituer ℓ à la MAPE dans l'Équation (6) permettrait de pénaliser plus sévèrement les sous-estimations (ou inversement, les sur-estimations) de gravité. Cette intégration est discutée comme perspective en Section 9.

6.8 Expression complète de ζ

$$\zeta(E(t)) = \tanh\left(\sum_{i=1}^{N(t)} \bar{\omega}_i \, \widetilde{\mathcal{G}}_i(t)\right), \tag{24}$$

où $\bar{\omega}_i$ sont les poids normalisés "statiques" (16) et $\widetilde{\mathcal{G}}_i(t)$ intègre la gravité résiduelle temporelle (4).

6.9 Résultats préliminaires

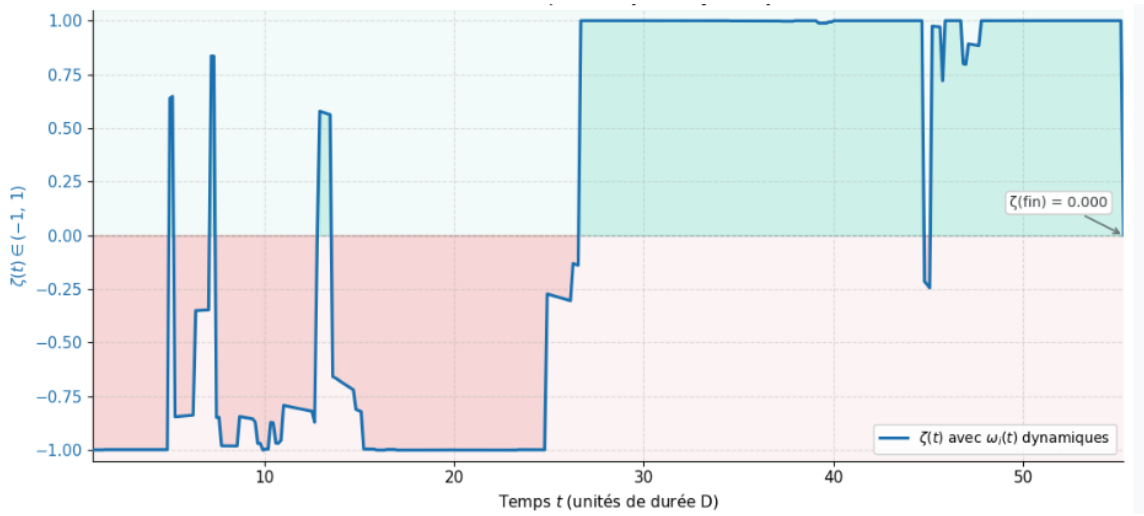


FIGURE 12 – $\zeta(t)$ sans dilatation ($\lambda = 1$) : stagnation excessive à ± 1, motivant l'introduction de λ (Section 7.2).

Nous pouvons désormais fournir une première analyse de l'état de santé de l'environnement synthétique généré aléatoirement pour cette expérience préliminaire.

L'élément le plus frappant est la démarcation nette entre la partie gauche et la partie droite du graphique, située aux alentours de 28 unités de temps.

En outre, ces deux régions apparaissent durablement figées aux valeurs limites, ce qui semble peu réaliste : cela reviendrait à supposer un environnement favorable à l'utilisateur à hauteur de 100 % sur une période prolongée.

Ce constat appelle une réduction de l'intensité effective des événements. Nous introduisons à cet effet, en Section 7.2, un facteur de dilatation permettant de compresser l'échelle des variations ; les résultats de son intégration y sont présentés et mettent en évidence l'amélioration apportée.

Toutefois, nous pouvons analyser si l'évolution de l'état de santé est cohérente avec le nombre d'événements au cours du temps, qu'ils soient positifs ou négatifs. Ainsi, on s'attend à observer une majorité d'événements négatifs dans la partie gauche de l'axe temporel, et une majorité d'événements positifs dans la partie droite.

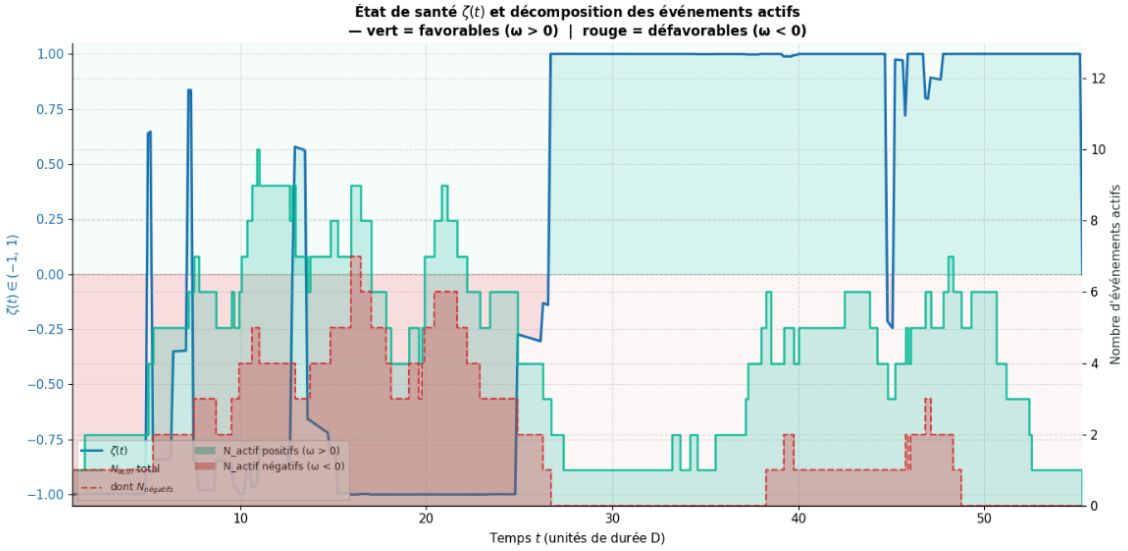


FIGURE 13 – Évolution conjointe de $\zeta(t)$ et du nombre d'événements actifs. La cohérence qualitative est confirmée.

Conformément à cette attente, on observe une majorité d'événements jugés positifs pour l'utilisateur dans la partie droite, avec toutefois quelques variations locales dues à l'ajout de certains événements négatifs.

De manière analogue, dans la partie gauche, on constate une supériorité des événements négatifs sur les événements positifs sur la majeure partie de l'intervalle, ce qui confirme la cohérence qualitative du modèle avec la structure de la base d'événements générée.

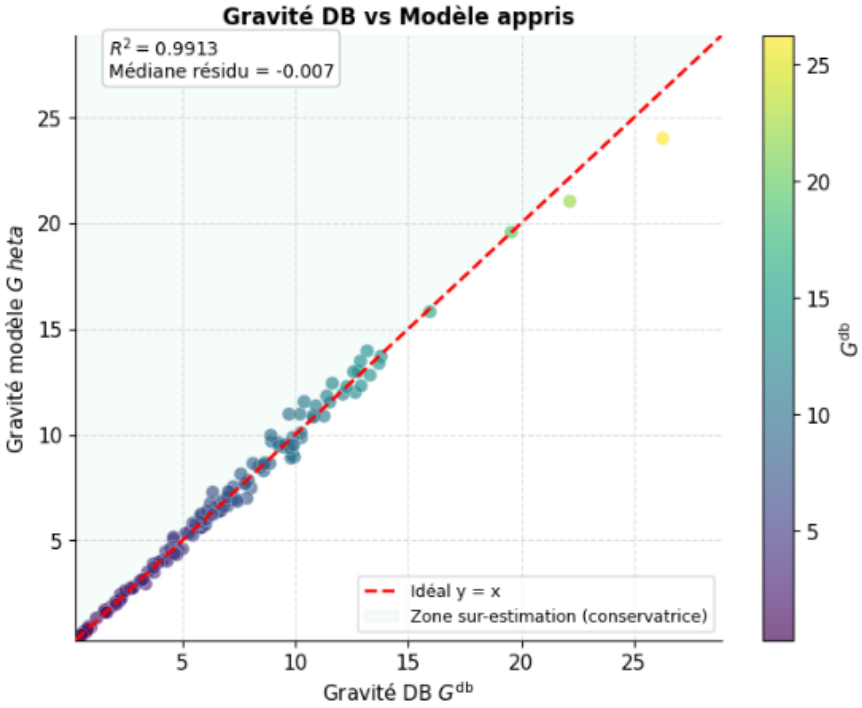


FIGURE 14 – $\hat{\mathcal{G}}$ vs $\mathcal{G}^{\text{db}}$: alignement sur $y = x$ avec $R^2 = 0{,}9913$.

Le tableau suivant récapitule, pour chacun des trois clusters synthétiques, les hyperparamètres $(\hat{\alpha}_k, \hat{\beta}_k, \hat{\delta}_k)$ estimés par la procédure de calibration de la Définition 3.7 : leur lecture détaillée fait l'objet de la sous-section 6.9.1 qui suit immédiatement.

6.9.1 Analyse des hyperparamètres de la loi de gravité

Cluster	$\lvert\mathcal{C}_k\rvert$	$\hat{\alpha}_k$	$\hat{\beta}_k$	$\hat{\delta}_k$
$\mathcal{C}_1$ (Financier)	29	0,7834	0,5608	0,5347
$\mathcal{C}_2$ (Climatique)	41	0,7883	0,6098	0,4990
$\mathcal{C}_3$ (Sanitaire)	35	0,8157	0,6052	0,4936

On considère la loi de gravité dynamique définie par :

$$\mathcal{G}(t) = \Gamma\big(\mathcal{D}_{\text{eff}}(t), \mathcal{F}, \mathcal{R}, \mathcal{P}\big) = \frac{\big[\max(\mathcal{D} - (t - t_0), 0)\big]^{\alpha} \cdot \mathcal{F}^{\beta} \cdot \mathcal{R}^{\delta}}{1 + \mathcal{P}^{\gamma}}. \tag{25}$$

Les paramètres $(\alpha_k, \beta_k, \delta_k)$ estimés par cluster contrôlent respectivement :

1. la décroissance temporelle effective ;
2. l'amplification de la fréquence ;
3. la diffusion spatiale ou sémantique.

1. Écarts sur l'amplitude temporelle (α_k).

On observe :

$$\hat{\alpha}_1 = 0{,}7834, \quad \hat{\alpha}_2 = 0{,}7883, \quad \hat{\alpha}_3 = 0{,}8157.$$

L'écart relatif maximal vaut :

$$\Delta\alpha_{\max} = \frac{0{,}8157 - 0{,}7834}{0{,}7834} \approx 4{,}1\%.$$

Cela indique une homogénéité forte de la décroissance temporelle entre clusters, avec une légère amplification pour le cluster sanitaire.

2. Écarts sur la sensibilité à la fréquence (β_k).

$$\hat{\beta}_1 = 0{,}5608, \quad \hat{\beta}_2 = 0{,}6098, \quad \hat{\beta}_3 = 0{,}6052.$$

L'écart relatif maximal est :

$$\Delta\beta_{\max} = \frac{0{,}6098 - 0{,}5608}{0{,}5608} \approx 8{,}7\%.$$

Ce résultat est significatif : la fréquence joue un rôle sensiblement plus important dans les clusters climatique et sanitaire que dans le cluster financier, ce qui traduit une dynamique d'accumulation plus marquée.

3. Écarts sur la diffusion spatiale (δ_k).

$$\hat{\delta}_1 = 0{,}5347, \quad \hat{\delta}_2 = 0{,}4990, \quad \hat{\delta}_3 = 0{,}4936.$$

L'écart relatif maximal vaut :

$$\Delta\delta_{\max} = \frac{0{,}5347 - 0{,}4936}{0{,}4936} \approx 8{,}3\%.$$

On observe ici une différence structurelle plus marquée : le cluster financier présente une diffusion plus large, tandis que les clusters climatique et sanitaire sont plus localisés.

Synthèse.

Globalement, les écarts entre hyperparamètres restent modérés (entre 4% et 9%), ce qui indique :

- une stabilité globale de la loi de gravité entre clusters ;
- une spécialisation principalement portée par β et δ ;
- une robustesse du modèle malgré la segmentation.

Ainsi, la loi de gravité conserve une structure cohérente tout en capturant des régimes dynamiques différenciés selon les clusters.

6.9.2 Draps variationnels des poids statiques ω_i

Au-delà des hyperparamètres $(\alpha_k, \beta_k, \delta_k, \gamma_k)$ de la loi de gravité, nous cherchons à présent à déterminer si les poids statiques ω_i eux-mêmes admettent une dépendance fonctionnelle exploitable vis à vis des variables descriptives de chaque événement, au sein de chacun des trois clusters.

En toute généralité, ω_i pourrait dépendre des quatre variables $(\mathcal{D}, \mathcal{F}, \mathcal{R}, \mathcal{P})$ associées à un événement. Toutefois, une visualisation directe d'une surface à quatre variables n'étant pas possible, nous restreignons ici l'étude à un drap $f_{\mathbf{a}}^{(n)}(\mathcal{D}, \mathcal{F})$ défini sur les deux seules variables $(\mathcal{D}, \mathcal{F})$ - une projection choisie pour sa lisibilité en trois dimensions, et non parce que $\mathcal{R}$ et $\mathcal{P}$ seraient

supposées non pertinentes a priori. Ce drap, polynôme de degré total n, est calibré par moindres carrés pour chaque cluster :

$$f_{\mathbf{a}}^{(n)}(\mathcal{D},\mathcal{F}) = \sum_{i+j\le n} a_{ij}\,\mathcal{D}^i\mathcal{F}^j, \qquad p_n = \binom{n+2}{2} = \frac{(n+1)(n+2)}{2} \text{ paramètres.} \tag{26}$$

Remarque 6.8 (Lecture de la formule (26))**.** *Il ne s'agit là de rien d'autre que du drap $f_{\mathbf{a}}^{(n)}$ de la Définition 6.10 (Équation (21)), appliqué au couple de variables $(x,y) = (\mathcal{D},\mathcal{F})$. Par exemple, au degré $n = 1$, cela donne simplement le plan $f_{\mathbf{a}}^{(1)}(\mathcal{D},\mathcal{F}) = a_{00} + a_{10}\mathcal{D} + a_{01}\mathcal{F}$: le poids prédit varie alors de façon purement linéaire avec la durée et la fréquence de l'événement, sans terme d'interaction $\mathcal{D}\mathcal{F}$ (celui-ci n'apparaît qu'à partir de $n = 2$).*

Le degré optimal n^* est sélectionné par validation croisée (5 tirages 80/20 répétés), en minimisant un critère pénalisé $\mathrm{RMSE}(n) + \mu\, p_n/m$ ($\mu = 0{,}05$) afin d'éviter la sur-paramétrisation lorsque le nombre de points m disponibles par cluster est faible (voir Remarque 6.5 pour une lecture intuitive de ce critère).

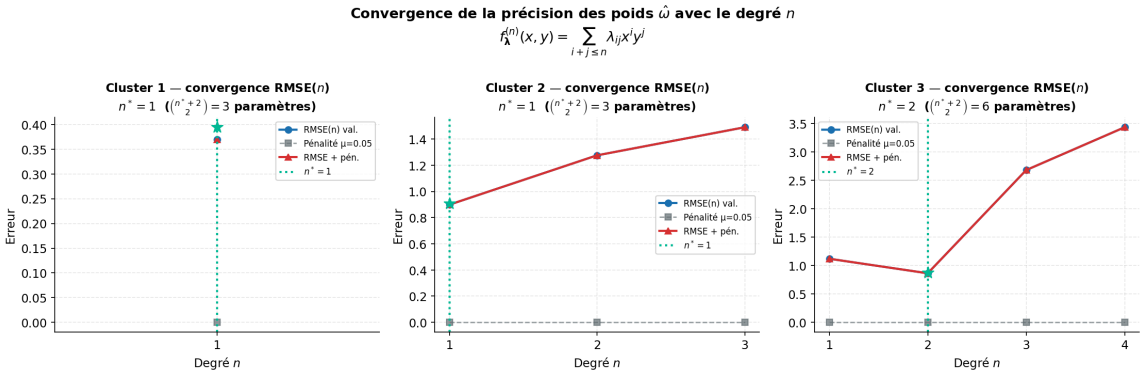


FIGURE 15 – Convergence du RMSE de validation croisée en fonction du degré n, par cluster.

Cluster	m (test)	n^*	p_{n^*}	$\mathrm{RMSE}(n^*)$	$\bar{I}(f^*)$	$\hat{\omega}(\mathcal{D}{=}4,\mathcal{F}{=}2)$
$\mathcal{C}_1$ (Financier)	6	1	3	0,3695	0,3514	−0,3711
$\mathcal{C}_2$ (Climatique)	17	1	3	0,8990	0,0029	+0,3981
$\mathcal{C}_3$ (Sanitaire)	22	2	6	0,8632	1,6994	−0,0970

TABLEAU 1 – Degré optimal, erreur de validation croisée, énergie normalisée $\bar{I}(f^*)$ et prédiction du poids pour un événement hypothétique $(\mathcal{D},\mathcal{F}) = (4,2)$, par cluster.

Les poids ω_i observés sur l'ensemble complet couvrent l'intervalle $[-1{,}49,\ 1{,}48]$, avec un équilibre quasi parfait entre poids positifs et négatifs (74 positifs / 76 négatifs sur 150 événements). Le RMSE de validation obtenu (entre 0,37 et 0,90) doit être comparé à l'écart-type théorique d'une loi uniforme sur cet intervalle, $\sigma = 3/\sqrt{12} \approx 0{,}87$: pour les clusters Climatique et Sanitaire, le RMSE de validation est du même ordre que σ, ce qui indique que **la projection $(\mathcal{D},\mathcal{F})$ retenue ne fait guère mieux qu'un modèle constant** (la moyenne locale du cluster).

Ce constat porte spécifiquement sur cette projection à deux variables : il ne permet pas, à lui seul, d'exclure une dépendance de ω_i à $\mathcal{R}$ et/ou $\mathcal{P}$, que la représentation en 3D ne permet pas d'explorer directement. Les prédictions pour un nouvel événement $(\mathcal{D},\mathcal{F}) = (4,2)$ diffèrent fortement d'un

cluster à l'autre en signe et en amplitude ($-0{,}37$, $+0{,}40$, $-0{,}10$), ce qui est cohérent avec des draps quasi plats calibrés sur peu de points : la prédiction reflète surtout la moyenne locale du cluster plutôt qu'une véritable dépendance géométrique à $(\mathcal{D}, \mathcal{F})$.

Cette lecture chiffrée peut être complétée par un aperçu visuel direct de la forme des draps $f^*(\mathcal{D}, \mathcal{F})$ calibrés au degré optimal n^* pour chacun des trois clusters (Figure 16). Les points observés y sont superposés au drap, colorés en vert lorsque $\omega_i \geq 0$ (événement favorable) et en rouge lorsque $\omega_i < 0$ (événement défavorable).

On y retrouve, de façon cohérente avec les résultats numériques du Tableau 1, des surfaces peu accidentées : un plan quasiment horizontal pour les clusters Financier et Climatique ($n^* = 1$), et une légère courbure pour le cluster Sanitaire ($n^* = 2$), sans relief marqué. Les points positifs et négatifs apparaissent entremêlés au-dessus et en dessous du drap plutôt que séparés par une frontière nette selon $\mathcal{D}$ ou $\mathcal{F}$ - signature visuelle de l'absence de structure géométrique exploitable relevée ci-dessus.

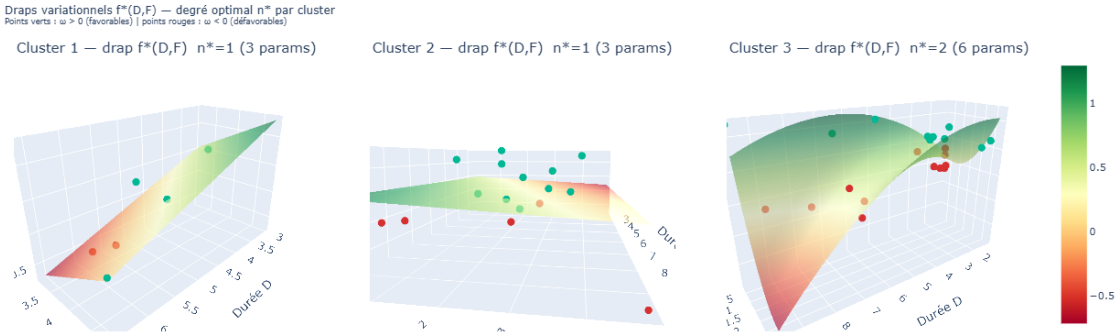


FIGURE 16 – Draps variationnels $f^*(\mathcal{D}, \mathcal{F})$ au degré optimal n^*, par cluster (Financier, Climatique, Sanitaire).

Un paradoxe apparent : la précision ne s'améliore pas avec n. On pourrait s'attendre à ce qu'un polynôme de degré plus élevé, disposant de davantage de paramètres, approxime toujours mieux les données. C'est effectivement vrai en erreur d'entraînement, mais pas en validation :

Cluster	n	RMSE train	RMSE validation
$\mathcal{C}_2$ (Climatique)	1	0,6054	0,8530
$\mathcal{C}_3$ (Sanitaire)	1	0,8150	0,9748
$\mathcal{C}_3$ (Sanitaire)	2	0,5777	0,9523

TABLEAU 2 – Diagnostic train/validation : le RMSE d'entraînement baisse avec n, mais le RMSE de validation stagne et l'écart entre les deux double entre $n = 1$ et $n = 2$ pour le cluster Sanitaire.

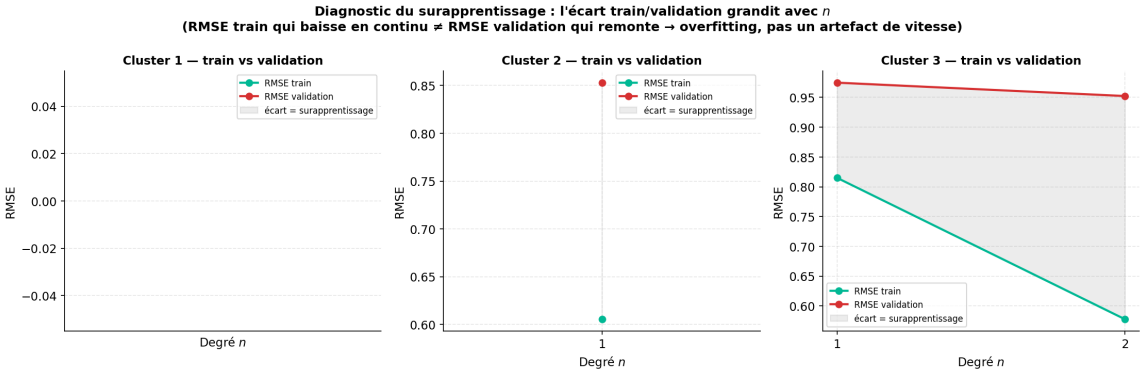


FIGURE 17 – RMSE train (vert) vs validation (rouge) par cluster ; l'écart grisé, signature du surapprentissage, croît avec n.

Le RMSE d'entraînement du cluster Sanitaire baisse de 0,815 à 0,578 entre $n = 1$ et $n = 2$, confirmant que le polynôme s'ajuste de mieux en mieux aux points *vus*. Mais le RMSE de validation ne suit pas cette tendance (amélioration marginale de 0,975 à 0,952), tandis que l'écart train/validation double (0,160 $\rightarrow$ 0,375) : c'est la signature classique du **surapprentissage** - le degré supplémentaire n'apporte pas de signal nouveau, il absorbe le bruit d'échantillonnage propre aux points d'entraînement.

La réserve méthodologique formulée plus haut sur la restriction à $(\mathcal{D}, \mathcal{F})$ peut en réalité être levée dans le cas précis de cette expérience préliminaire : la construction même de la base synthétique montre que les poids statiques y sont générés par $\omega_i \sim \mathcal{U}(-1{,}5,\ 1{,}5)$, **indépendamment des quatre variables** $\mathcal{D}$, $\mathcal{F}$, $\mathcal{R}$ et $\mathcal{P}$.

Il n'existe donc, par construction, aucune fonction $f(\mathcal{D}, \mathcal{F}, \mathcal{R}, \mathcal{P})$ sous-jacente à retrouver - la relation réelle est un bruit pur plutôt qu'une surface lisse, quelle que soit la paire de variables choisie pour la projection. Ce n'est donc pas ici un artefact du choix de $(\mathcal{D}, \mathcal{F})$ plutôt que $(\mathcal{R}, \mathcal{P})$: sur des données réelles où cette information de génération ne serait pas disponible, la même conclusion devrait être vérifiée en croisant plusieurs projections (ou, mieux, en ajustant un drap sur les quatre variables sans passage par une visualisation directe) avant d'être retenue. Le critère pénalisé sélectionne d'ailleurs correctement des degrés bas ($n^* \in \{1, 2\}$), ce qui constitue le comportement attendu du garde-fou face à une cible sans structure exploitable, plutôt qu'une limite de la méthode.

7 Extensions du modèle

7.1 Introduction

Les résultats préliminaires de la Section 6 ont mis en évidence trois limitations pratiques du modèle de base : une saturation prématurée de ζ aux bornes ± 1, une sensibilité insuffisante aux variations locales lorsque le nombre d'événements actifs devient élevé, et l'absence de mécanisme de calibration automatique des hyper-paramètres.

Les sections suivantes traitent successivement ces trois points, avant d'aborder l'extension du modèle à des événements ne correspondant à aucun cluster préexistant.

7.2 Ajustement de la sensibilité par dilatation

Les premières simulations ont mis en évidence un phénomène de saturation prématurée de ζ aux bornes ± 1, limitant la capacité de discrimination dans les régimes fortement extrêmes. Afin de contrôler ce comportement, nous introduisons un paramètre de dilatation.

Définition 7.1 (Dilatation)**.** *[Contribution originale de l'auteur.]*

La fonction d'état dilatée est définie par :

$$\zeta_\lambda(E(t)) = \tanh\left(\frac{S(t)}{\lambda}\right), \quad \lambda > 0. \tag{27}$$

où λ contrôle l'échelle de saturation de la réponse.

On fera la distinction entre le λ de cette définition et les $\lambda_{i,j}$ de la partie 6.8.2.

Remarque 7.1 (Notation)**.** *Afin d'éviter toute ambiguïté avec les coefficients du drap variationnel de la Section 6.6, ces derniers ont été notés a_{ij} (et non λ_{ij}) : λ est ainsi, dans toute la suite de l'article, réservé exclusivement au paramètre de dilatation ci-dessus.*

Proposition 7.1 (Propriétés de ζ_λ)**.** *La famille de fonctions ζ_λ vérifie les propriétés suivantes :*

- *Sensibilité locale : $\zeta'_\lambda(0) = \frac{1}{\lambda}$, ce qui montre que la sensibilité autour de l'origine est inversement proportionnelle à λ ;*
- *Seuil de saturation : $\zeta_\lambda \approx 0{,}95$ dès que $|S| \geq 1{,}83\,\lambda$, indiquant un contrôle direct de la zone de non-linéarité ;*
- *Régime diffus : lorsque $\lambda \to +\infty$, on a $\zeta_\lambda(E(t)) \to 0$, ce qui correspond à une perte progressive de sensibilité et donc d'information.*

λ	Dérivée en 0	$\lvert S\rvert$ pour $\zeta = 0{,}95$	Interprétation
0,5	2,00	0,91	Très sensible, saturation rapide
1	1,00	1,83	Standard (problème de paliers)
5	0,20	9,16	Filtre modéré, utilisé en pratique
20	0,05	36,6	Filtre fort
100	0,01	183	Quasi-linéaire

Tableau 3 – Effet de λ sur la sensibilité de ζ_λ.

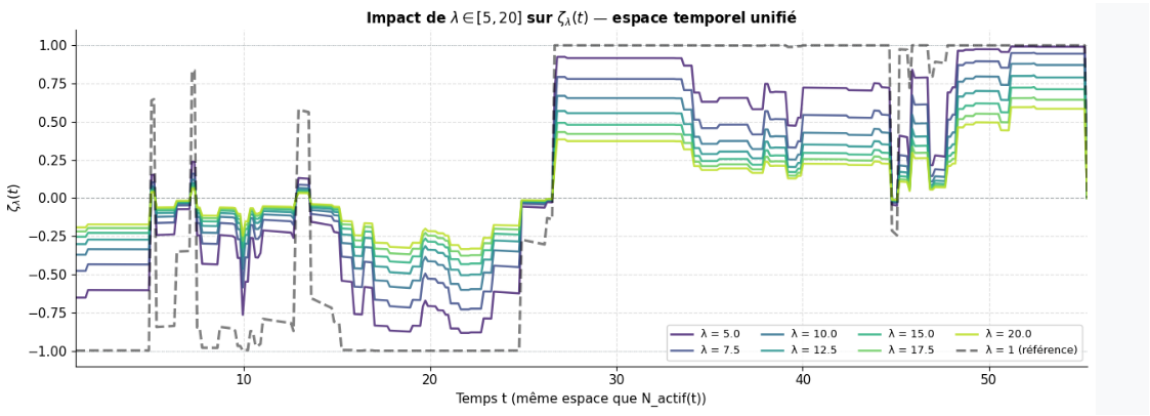


FIGURE 18 – $\zeta_\lambda(t)$ pour différentes valeurs de λ : atténuation progressive des effets de saturation aux extrémités.

L'analyse des résultats montre que l'introduction du paramètre λ permet de contrôler efficacement le phénomène de saturation de l'état de santé aux bornes ± 1. Les valeurs intermédiaires telles que $\lambda \in \{7.5,\ 10,\ 12.5\}$ apparaissent comme un compromis pertinent, en conservant une dynamique lisible tout en évitant un écrasement excessif de l'information.

Problème d'échelle temporelle.

Une difficulté apparaît toutefois lorsque l'environnement accumule un grand nombre d'événements, même de faible intensité. Dans ce cas, la contribution cumulée tend à croître artificiellement, ce qui impose une adaptation du paramètre de régularisation.

Pour répondre à ce phénomène, nous introduisons une dépendance du paramètre λ à la structure temporelle de l'environnement :

$$\lambda(t) = f\big(N(t)\big), \tag{28}$$

où $N(t)$ représente le nombre d'événements actifs à l'instant t.

Choix du modèle.

Parmi les différentes formes possibles pour f, nous retenons une version volontairement simple et interprétable :

$$\lambda(t) = N(t). \tag{29}$$

Ce choix se justifie par plusieurs considérations :

— $N(t)$ constitue une mesure directe de la densité informationnelle du système ;
— la dépendance linéaire assure une adaptation proportionnelle à la complexité locale ;
— l'absence de paramètres supplémentaires limite les risques de sur-ajustement ;
— la lecture de λ reste directement liée à une quantité observable.

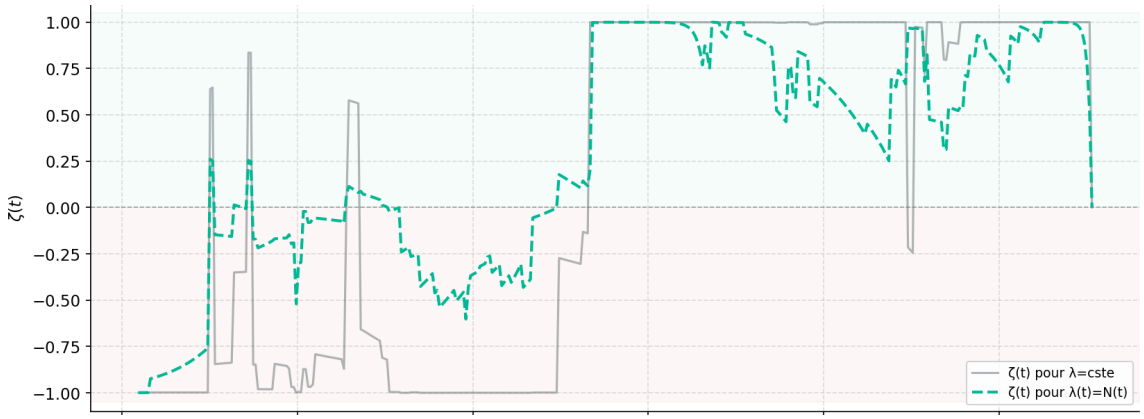


FIGURE 19 – $\zeta_\lambda(t)$ pour $\lambda(t) = 1$ et $\lambda(t) = N(t)$

Contrairement à la configuration à facteur de dilatation constant, les résultats obtenus ici mettent en évidence un comportement nettement plus nuancé de la dynamique de $\zeta_\lambda(t)$.

Avec λ fixé, la somme pondérée $S(t)$ peut dépasser le seuil de saturation de tanh dès que le nombre d'événements actifs devient suffisamment élevé, comprimant artificiellement ζ_λ dans une plage réduite. L'introduction d'un paramètre adaptatif $\lambda(t) = \alpha\, N(t)$ compense directement cette accumulation : à mesure que $N(t)$ croît, le seuil de saturation $\lambda(t)$ croît proportionnellement, restaurant une échelle dynamique naturelle et une meilleure répartition des variations sur $[-1, 1]$.

Cependant, des plateaux locaux sur de courtes fenêtres temporelles persistent. Ce phénomène s'explique par des phases où $N(t)$ varie lentement : le dénominateur $\lambda(t)$ reste quasi-constant, et des séries d'événements de même polarité peuvent à nouveau saturer tanh. Pour y remédier, nous proposons de rendre la saturation exponentiellement difficile à atteindre en introduisant une pénalisation croissante du second ordre :

Définition 7.2 (Dilatation adaptative pénalisée)**.** *[Contribution originale de l'auteur.]*

On définit le paramètre de dilatation adaptatif par :

$$\lambda(t) = \frac{\alpha\, N(t)}{1 + \beta\, |\zeta_\lambda(t-1)|}, \quad \alpha > 0,\ \beta > 0, \tag{30}$$

où $t-1$ désigne l'instant précédent, $\alpha > 0$ est le facteur de calibration global, et $\beta > 0$ contrôle l'intensité de la correction anti-plateau.

La récurrence est amorcée par la condition initiale $\zeta_\lambda(t_0 - 1) := 0$, correspondant à un environnement neutre avant la première observation.

Quand $|\zeta_\lambda(t^-)| \to 1$, λ diminue, rendant tanh plus pentu et forçant ζ à revenir vers le centre. Ce mécanisme encode précisément le *principe d'impossibilité des extrêmes absolus* introduit en Section 6.4.

- Zone neutre ($|\zeta_\lambda(t^-)| \approx 0$) : le dénominateur vaut ≈ 1, la correction est négligeable et $\lambda(t)$ se réduit à $\alpha\, N(t)$;
- Saturation imminente ($|\zeta_\lambda(t^-)| \approx 1$) : le dénominateur atteint $1 + \beta$, réduisant $\lambda(t)$ et rendant tout franchissement supplémentaire vers ± 1 progressivement difficile.

En d'autres termes, plus ζ_λ s'approche des bornes, plus le modèle « résiste » à les atteindre - ce qui encode précisément le principe d'impossibilité des extrêmes absolus introduit en Section 6.4.

Remarque 7.2. *Les deux cas limites permettent de retrouver les formulations antérieures :*

— $\beta = 0$ *:* $\lambda(t) = \alpha\, N(t)$*, dilatation proportionnelle au nombre d'événements sans pénalisation ;*

— $\beta = 0$ *et* $N(t) \equiv N_0$ *constant, avec* $\alpha = \lambda_0/N_0$ *:* $\lambda(t) = \lambda_0$*, on retrouve le facteur constant (Section 7.2).*

Remarque 7.3 (Condition de non-franchissement)**.** *Le mécanisme précédent* ralentit *la progression vers* ± 1*, mais ne l'empêche pas formellement en toute généralité :* ζ_λ *peut continuer à progresser vers les bornes tant que* $S(t)$ *croît plus vite que* $\lambda(t)$*. Plus précisément, si* $1+\beta|\zeta_\lambda(t-1)| > \alpha N(t)$ *- c'est-à-dire lorsque la correction anti-plateau au dénominateur l'emporte sur l'effet brut de* $N(t)$ *au numérateur -, alors* $\lambda(t)$ *est* inférieur *à ce qu'il vaudrait sans pénalisation, ce qui accélère au contraire la saturation locale de* tanh *plutôt que de la freiner. Le paramètre* β *doit donc être calibré de sorte que cette inégalité ne soit vérifiée qu'au voisinage immédiat de* $|\zeta_\lambda| \to 1$ *(où l'effet recherché - freiner l'approche de la borne - reste cohérent), et non sur une plage étendue de valeurs de* ζ_λ*, faute de quoi la pénalisation produirait localement l'effet inverse de celui recherché. C'est précisément ce compromis qui motive le choix de* (α, β) *illustré ci-dessous (Figure 21).*

Remarque 7.4. *Cette extension peut s'avérer pertinente dans les situations où l'on observe une présence excessive de plateaux récurrents dans la dynamique de* $\zeta_\lambda(t)$*. L'introduction de* α *permet alors d'ajuster finement l'intensité de la dilatation et de restaurer une meilleure sensibilité aux variations locales.*

Validation du facteur de dilatation adaptatif.

L'objectif de cette expérience est de vérifier que l'introduction du facteur de dilatation adaptatif permet de limiter les phénomènes de saturation de $\zeta_\lambda(t)$ aux bornes extrêmes -1 et 1.

$$\lambda(t) = \frac{\alpha\, N(t)}{1 + \beta\, |\zeta_\lambda(t-1)|}$$

Afin d'illustrer le comportement attendu de ce facteur de dilatation, nous proposons un graphique simulé. Ce graphique, volontairement idéalisé, n'a pas vocation à reproduire fidèlement un cas réel : il sert uniquement à mettre en évidence, de manière pédagogique, l'effet recherché.

Une comparaison avec une version calibrée sur des données ultérieures sera nécessaire afin d'évaluer précisément l'efficacité du mécanisme en conditions réelles.

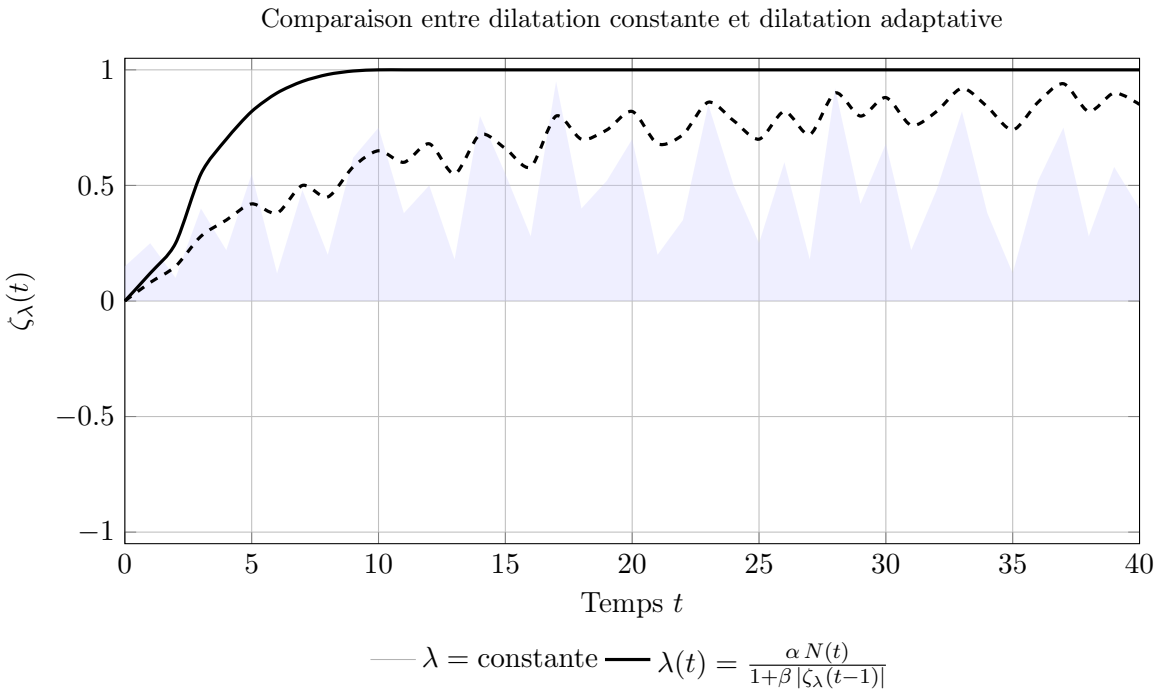


FIGURE 20 – Comparaison entre une dilatation constante et une dilatation adaptative.

Afin d'illustrer ce comportement, nous comparons :

— un modèle à dilatation constante ;

— un modèle à dilatation adaptative dépendant du nombre d'événements actifs $N(t)$.

Dans le cas d'un facteur de dilatation constant, les fortes accumulations d'événements conduisent rapidement à des plateaux, ce qui réduit fortement la dynamique du signal et entraîne une perte d'information sur les variations locales de l'environnement.

La zone pastel transparente représente ici l'évolution du nombre d'événements actifs dans l'environnement. Idéalement, le facteur de dilatation permet ainsi de tasser les pics d'intensité afin d'éviter tout excès ou toute surcharge artificielle dans l'évaluation de l'état de santé.

Ce modèle nécessite toutefois de déterminer un couple d'hyperparamètres (α, β). Ce choix n'est pas anodin : selon le contexte et l'environnement considéré, ce couple peut varier de manière significative (voir Remarque 7.3 pour la contrainte que ce couple doit respecter).

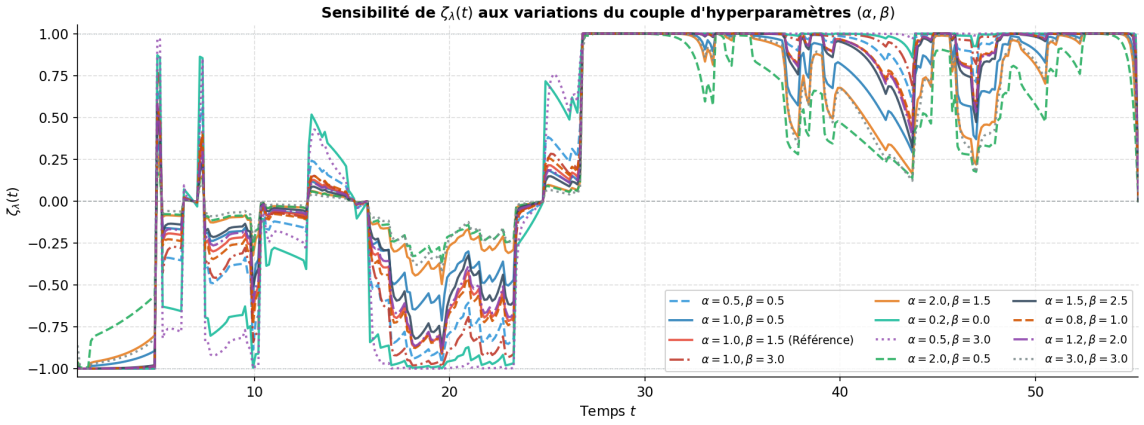


FIGURE 21 – État de santé selon le couple (α, β).

Dans notre cas, le couple $\alpha = 2$ et $\beta = 0{,}5$ semble constituer le meilleur compromis, dans la mesure où il produit la courbe la plus représentative du comportement attendu. Autrement dit, ce couple est celui qui retarde le plus longtemps l'apparition de plateaux.

7.3 Lissage temporel par interpolation

7.3.1 Lagrange et phénomène de Runge

Définition 7.3 (Polynôme de Lagrange). *[Résultat standard de la littérature.]*

$$\hat{\zeta}(t) = \sum_{k=0}^{n} \zeta_k \ell_k(t), \qquad \ell_k(t) = \prod_{j \neq k} \frac{t - t_j}{t_k - t_j}. \tag{31}$$

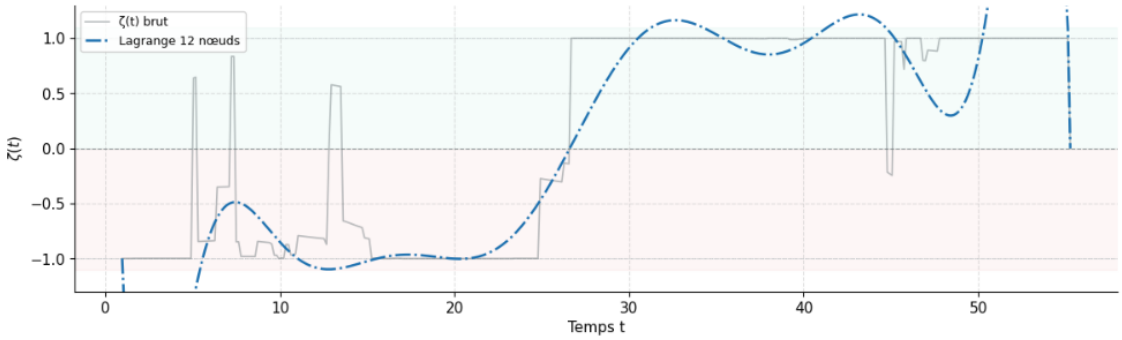


FIGURE 22 – Lissage de Lagrange : sorties hors $[-1, 1]$ (phénomène de Runge).

Comme nous pouvons le constater clairement, l'interpolation de Lagrange conduit à un lissage qui dépasse largement le domaine d'étude de l'état de santé, défini sur l'intervalle $[-1, 1]$. Ainsi, nous ne pouvons pas nous appuyer sur cette méthode dans notre cadre d'analyse.

C'est pourquoi nous nous orientons vers une autre méthode de lissage, à savoir les splines cubiques.

7.3.2 Splines cubiques - méthode recommandée

Définition 7.4 (Spline cubique naturelle). *[Résultat standard de la littérature.]*

[5] Fonction $\mathcal{C}^2$, polynomiale par morceaux (degré 3), minimisant $\int [\hat{\zeta}'']^2 \, dt$.

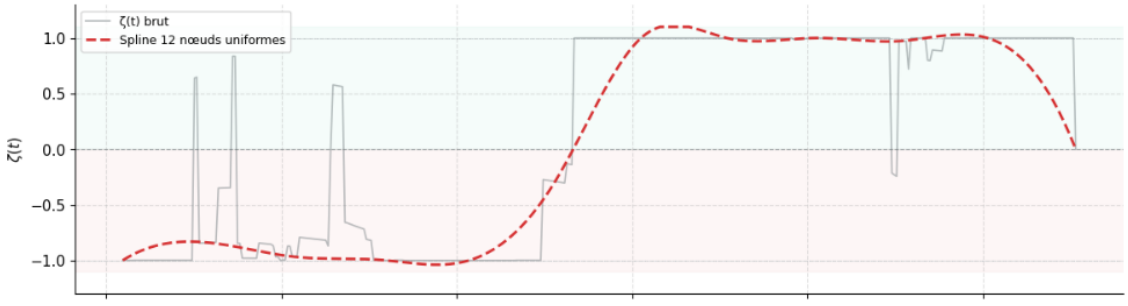


FIGURE 23 – Lissage par spline cubique : courbe bornée dans $[-1, 1]$.

Contrairement à l'interpolation de Lagrange, le domaine de définition de l'état de santé est respecté, malgré l'apparition de légers écarts relatifs de l'ordre de quelques pourcents. Dans un cadre d'analyse qualitative, ces écarts restent acceptables dans la mesure où l'objectif principal est d'identifier les zones où l'environnement est fortement favorable ou défavorable à l'utilisateur.

Cependant, une limitation importante apparaît lorsqu'on s'intéresse aux variations sur des fenêtres temporelles très courtes. Ces fluctuations locales ne sont pas correctement capturées par le lissage induit par les splines cubiques.

Cette limite provient directement du choix des nœuds, qui sont répartis de manière uniforme sur l'ensemble de l'axe temporel. Une telle distribution ne permet pas d'adapter la résolution aux zones présentant des variations rapides ou des discontinuités locales.

Il devient donc nécessaire d'envisager une densification adaptative des nœuds dans les régions où la dynamique devient fortement non linéaire. Cette idée conduit naturellement à la section suivante.

7.3.3 Splines adaptatives aux discontinuités

L'idée qui suit - densifier les points de mesure autour d'une variation brutale pour mieux en capturer la forme, plutôt que d'échantillonner uniformément l'ensemble du domaine - n'est pas sans rappeler la pratique du dosage pH-métrique en chimie, où l'on resserre les prises de mesure autour du point d'équivalence pour mieux capturer le saut de pH.

Définition 7.5 (Nœuds adaptatifs)**.** *[Contribution originale de l'auteur.]*

$$\mathcal{T}_{\text{disc}} = \{t_k, t_{k+1} \mid \Delta_k > \Delta_{\text{seuil}}\}, \qquad \Delta_k = |\zeta(t_{k+1}) - \zeta(t_k)|. \tag{32}$$

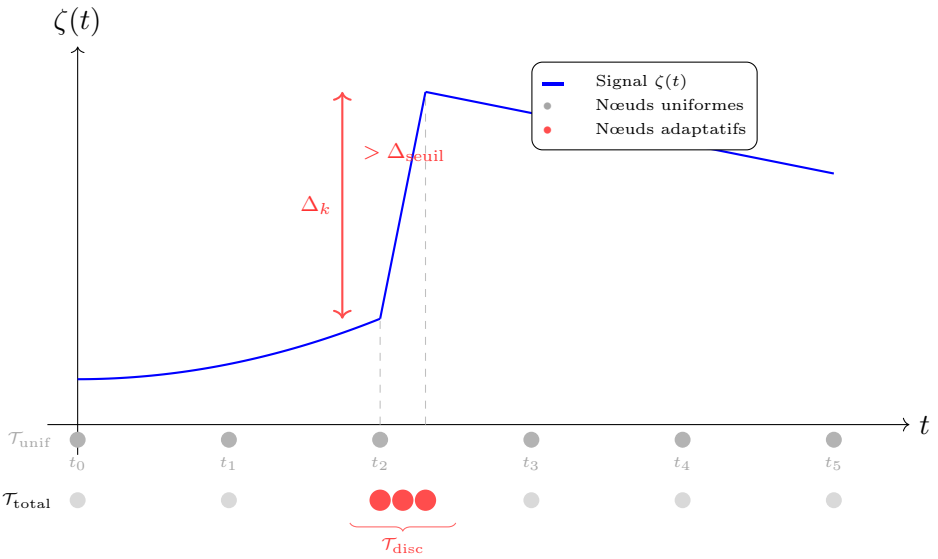


FIGURE 24 – Enrichissement de la grille : nœuds adaptatifs injectés autour des sauts $\Delta_k > \Delta_{\text{seuil}}$.

Comme le montre l'illustration, la détection d'une discontinuité dans l'évolution de l'état de santé conduit à un raffinement local de la discrétisation temporelle. L'idée consiste à augmenter la densité de nœuds dans les zones où la dynamique présente des variations brusques, afin d'en améliorer la résolution.

Cette stratégie permet de mieux capturer les comportements locaux du signal et d'améliorer la qualité du lissage dans les régions fortement non linéaires.

On note N_{unif} le nombre de nœuds initialement répartis de manière uniforme sur l'intervalle temporel étudié. Pour chaque point de discontinuité détecté t_k, on introduit un ensemble supplémentaire de nœuds, dont la cardinalité est notée n_k, afin de raffiner localement la grille.

Le nombre total de nœuds s'écrit alors :

$$N_{\text{total}} = N_{\text{unif}} + \sum_{k \in \mathcal{D}} (n_k - 1), \tag{33}$$

où $\mathcal{D}$ désigne l'ensemble des indices des discontinuités détectées.

Le terme $(n_k - 1)$ permet de corriger le double comptage du nœud central déjà présent en t_k, lors de l'ajout des points de raffinement locaux.

Ainsi, la discrétisation temporelle devient adaptative : sa densité dépend directement de la complexité locale du signal $\zeta(t)$.

Nous allons à présent combiner les résultats de cette section avec ceux de la section consacrée à l'ajustement de la sensibilité par dilatation (Section 7.2).

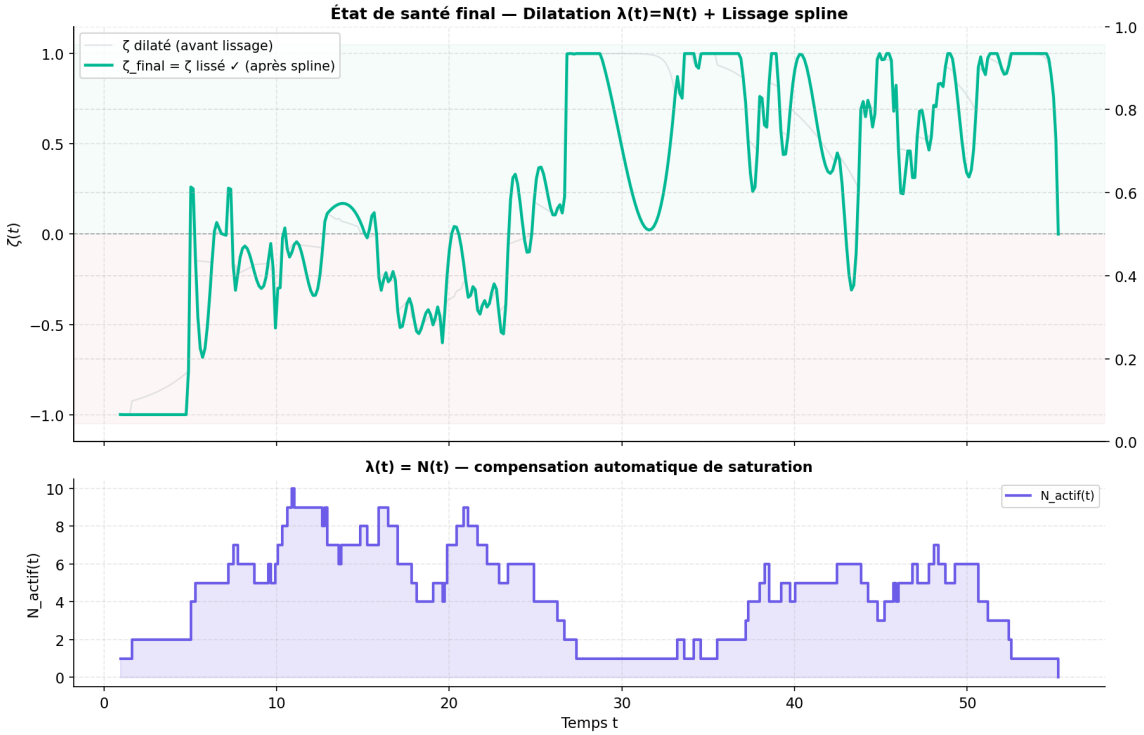


FIGURE 25 – Lissage temporel de l'état de santé selon spline cubique adaptative.

On peut en conclure que le lissage adaptatif permet de suivre fidèlement la courbe, même si un écart plus ou moins important peut être observé par endroits. En effet, le décalage absolu maximal ($|\Delta\zeta|$) culmine à environ 1,0 (soit 50 % de l'amplitude totale du signal) aux alentours de $t = 31$, où la courbe lissée chute à 0,0 alors que le signal d'origine sature à 1,0. De plus, de multiples autres déviations majeures, comprises entre 0,3 et 0,7, sont observables tout au long du signal, notamment autour de $t = 38$ et $t = 44$.

Ce résultat est satisfaisant : hormis ces quelques écarts, le lissage remplit son rôle sans omettre d'informations fines, ce qui faisait précisément défaut aux versions précédentes du lissage. Il présente en outre l'avantage de respecter strictement le domaine de définition de l'état de santé, la courbe demeurant toujours comprise entre -1 et 1, y compris lorsque des plateaux se forment.

La principale performance obtenue est ainsi une approximation plus fidèle de la courbe réelle, tout en préservant les subtilités de cette dernière.

Analyse qualitative et discussion critique :
Cependant, d'un point de vue purement qualitatif, ce lissage présente un compromis important qui mérite d'être souligné. Si la capacité de la spline à coller aux dynamiques rapides est positive, elle se fait au détriment de la stabilité locale.

L'apparition de creux profonds et injustifiés (notamment à $t = 31$ et $t = 44$) là où le signal

d'origine est pourtant stable ou texturé montre un phénomène d'oscillations parasites typiques des splines mal contraintes sur des transitions abruptes.

En conclusion, le lissage est **excellent pour capturer la réactivité et les extrema** du système, mais **défaillant pour restituer la platitude des paliers**, en introduisant un bruit haute fréquence artificiel là où le signal réel était lisse.

7.4 Apprentissage par validation croisée K-fold

7.4.1 Introduction

La MAPE (Définition 3.6) est choisie dans notre cadre car elle permet de quantifier l'erreur de manière *relative* et donc indépendante de l'échelle des données. Cette propriété est particulièrement pertinente pour l'évaluation de l'opérateur Γ, dont les sorties correspondent à une gravité normalisée de l'état de santé.

De plus, son expression en pourcentage facilite l'interprétation directe des performances du modèle, ce qui permet une comparaison claire entre différentes configurations (globales ou par cluster), comme dans la validation croisée K-fold définie en Définition 7.6. Rappelons, pour la lisibilité de ce qui suit, que $\hat{\theta}_k = (\hat{\alpha}_k, \hat{\beta}_k, \hat{\delta}_k, \hat{\gamma}_k)$ désigne, comme en Définition 3.7, le jeu de paramètres calibré pour le cluster $\mathcal{C}_k$.

Définition 7.6 (Validation croisée K-fold)**.** *[Résultat standard de la littérature.]*

(appliquée ici à Γ) :

$$\hat{\theta} = \arg\min_{\theta} \frac{1}{K} \sum_{k=1}^{K} \mathrm{MAPE}(\Gamma_\theta, \mathcal{F}_k). \tag{34}$$

7.4.2 Analyse des performances du modèle

Cette comparaison poursuit un double objectif : confirmer, *a posteriori*, la pertinence du choix - fait dès la Section 3.4 et annoncé en Remarque 3.4 - de calibrer Γ par cluster plutôt que globalement, choix sur lequel reposent l'ensemble des sections qui suivent ; et quantifier le gain apporté par les raffinements successifs introduits depuis (dilatation, lissage adaptatif, etc.), qui s'appuient tous sur cette même structuration en clusters.

Modèle	**MAPE**	R^2
Global (sans cluster)	4,32%	0,9913
Par cluster	4,10%	—
Meilleur ($\mathcal{C}_3$)	3,35%	—

Les résultats obtenus montrent que le modèle possède une très bonne capacité de prédiction, avec des erreurs relatives faibles sur l'ensemble des expériences réalisées.

1. Modèle global.

Le modèle entraîné sans séparation en clusters atteint une erreur moyenne absolue relative :

$$\mathrm{MAPE} = 4{,}32\%.$$

Cette valeur indique que l'écart moyen entre les prédictions et les valeurs observées reste inférieur à 5%, ce qui traduit une bonne précision globale du modèle.

Le coefficient de détermination associé vaut :

$$R^2 = 0{,}9913.$$

Ainsi, plus de 99% de la variance observée est expliquée par le modèle, ce qui témoigne d'une très forte cohérence entre les prédictions et les données réelles.

2. Effet de la structuration par clusters.

L'introduction d'une séparation des données par clusters améliore légèrement les performances :

$$\text{MAPE} = 4{,}10\%.$$

Cette diminution de l'erreur suggère que les dynamiques propres à certaines catégories d'événements sont mieux capturées lorsqu'un modèle spécialisé est utilisé localement.

Autrement dit, la structuration en clusters permet de réduire l'hétérogénéité globale des données et d'obtenir des estimations plus adaptées aux comportements spécifiques de chaque groupe.

3. Cas du cluster $\mathcal{C}_3$.

Le cluster $\mathcal{C}_3$ constitue le cas le plus performant :

$$\text{MAPE} = 3{,}35\%.$$

Une telle valeur indique que les événements appartenant à ce cluster présentent probablement :

- une structure interne plus homogène ;
- des relations plus régulières entre les variables ;
- ou encore une dynamique plus facilement modélisable.

4. Interprétation globale.

Globalement, les différentes métriques obtenues confirment :

- la stabilité numérique du modèle ;
- sa capacité à reproduire fidèlement les comportements observés ;
- l'intérêt d'une approche locale par clusters ;
- ainsi que la pertinence des hypothèses de régularité introduites précédemment.

Les écarts résiduels observés proviennent principalement :

- des zones présentant de fortes variations locales ;
- des transitions rapides entre différents régimes dynamiques ;
- ou encore des événements atypiques difficilement interpolables.

7.5 Apprentissage par Q-Learning

Les sections précédentes ont mis en évidence plusieurs hyperparamètres dont le réglage manuel est délicat : le couple (α, β) de la dilatation adaptative (Section 7.2), le seuil Δ_{seuil} des nœuds adaptatifs (Section 7.3.3), ou encore les exposants $(\alpha_k, \beta_k, \delta_k, \gamma_k)$ de la loi de gravité par cluster (Section 3.4), pour l'instant calibrés par minimisation directe de la MAPE (Équation (6)). Nous explorons dans cette section la possibilité de confier ce réglage à un agent apprenant par renforcement plutôt qu'à une simple procédure d'optimisation directe, dans l'espoir d'automatiser et d'affiner cette calibration.

L'apprentissage par *Q-Learning* est un algorithme d'apprentissage par renforcement, dit *model-free* (« sans modèle de transition fourni a priori ») : il n'exige aucune connaissance préalable du *modèle de transition* de l'environnement, c'est-à-dire de la fonction $P(s' \mid s, a)$ donnant la probabilité de passer de l'état s à l'état s' sous l'effet de l'action a, une quantité qu'exigent, à l'inverse, les méthodes de programmation dynamique classiques.

Son objectif est d'apprendre une politique d'action optimale qui maximise la récompense cumulée d'un agent interagissant avec son environnement, sans nécessiter de connaissance préalable des lois physiques ou logiques qui régissent cet environnement.

7.5.1 Principes fondamentaux

Le Q-Learning repose sur l'évaluation de la qualité d'une action donnée dans un état spécifique. L'agent maintient et met à jour une fonction de valeur action-état, notée $Q(s, a)$. Cette fonction représente l'espérance mathématique des récompenses futures si l'agent exécute l'action a depuis l'état s, puis suit la politique optimale pour les étapes suivantes.

Le fonctionnement de l'algorithme s'articule autour des concepts clés suivants :

- L'État ($s \in S$) : La représentation numérique ou symbolique de la situation actuelle de l'agent dans son environnement.
- L'Action ($a \in A$) : La décision prise par l'agent parmi un ensemble d'actions possibles dans l'état s.
- La Récompense (r) : Le signal scalaire renvoyé par l'environnement après l'exécution de l'action, évaluant son efficacité immédiate (positive pour un succès, négative pour une pénalité).
- La Politique (π) : La stratégie globale de l'agent, définissant quelle action choisir pour chaque état. La politique optimale est notée π^*.

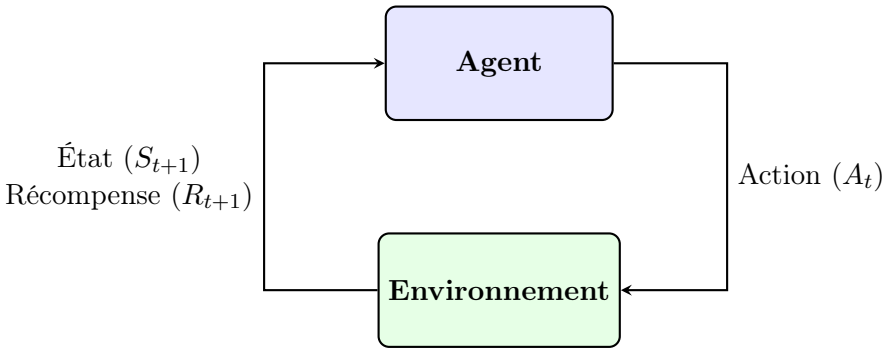


FIGURE 26 – Schéma classique de la boucle d'interaction entre l'agent et l'environnement en apprentissage par renforcement.

7.5.2 L'Équation de Bellman et la mise à jour des valeurs

Dans les environnements discrets, les valeurs Q sont généralement stockées dans une matrice appelée **Q-Table**. L'algorithme utilise une approche de différence temporelle pour mettre à jour itérativement les valeurs de cette table après chaque interaction, grâce à l'équation de Bellman modifiée :

$$Q(s,a) \leftarrow Q(s,a) + \eta \left[r + \kappa \max_{a'} Q(s',a') - Q(s,a) \right] \tag{35}$$

Remarque 7.5. *Les hyperparamètres du Q-Learning sont notés η (taux d'apprentissage) et κ (facteur d'actualisation) afin d'éviter toute confusion avec les exposants $\alpha, \beta, \delta, \gamma$ de la loi de gravité (Définition 3.3), que l'agent cherche précisément à calibrer en Section 7.5.*

Cette formule de mise à jour s'appuie sur plusieurs hyperparamètres essentiels au bon apprentissage de l'agent :

- Le taux d'apprentissage ($\eta \in [0,1]$) : Il détermine la vitesse à laquelle les nouvelles informations écrasent les anciennes. Un $\eta = 0$ empêche l'agent d'apprendre, tandis qu'un $\eta = 1$ le rend totalement amnésique face à son expérience passée, ne conservant que la toute dernière observation.
- Le facteur d'actualisation ou d'escompte ($\kappa \in [0,1]$) : Il pondère l'importance des récompenses futures par rapport aux récompenses immédiates. Un κ proche de 0 rendra l'agent myope et opportuniste, tandis qu'un κ proche de 1 le poussera à privilégier des stratégies à long terme.
- La cible d'apprentissage ($r + \kappa \max_{a'} Q(s',a')$) : Elle représente la valeur réelle observée, c'est-à-dire la récompense immédiate r additionnée à l'estimation de la meilleure valeur possible dans le nouvel état s'.

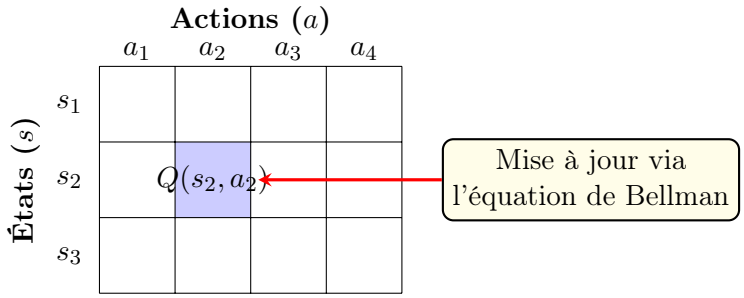


FIGURE 27 – Mécanisme de mise à jour d'une cellule de la Q-Table.

7.5.3 Le dilemme Exploration vs Exploitation

Pour converger vers la politique optimale, l'agent doit parcourir son environnement de manière exhaustive. Il fait face à un compromis permanent :

- L'Exploitation : Choisir l'action qui possède la plus grande valeur Q connue pour maximiser le gain immédiat.
- L'Exploration : Choisir une action sous-optimale ou aléatoire dans le but de découvrir de nouvelles trajectoires potentiellement plus rentables à l'avenir.

Pour gérer ce dilemme, l'approche la plus courante est la stratégie **ϵ-greedy** (epsilon-gloutonne). À chaque étape, l'agent choisit d'explorer avec une probabilité ϵ, et d'exploiter ses connaissances avec une probabilité $1 - \epsilon$. En pratique, la valeur de ϵ est souvent initialisée à 1 (exploration totale au début de l'apprentissage) puis décroît progressivement vers 0 (exploitation maximale une fois l'environnement connu).

7.5.4 Application au modèle fonctionnel de quantification de l'état de santé

Pourquoi cette synergie est pertinente : Le modèle fonctionnel développé introduit l'opérateur $\zeta(t)$, calculant un scalaire normalisé dans l'intervalle $(-1, 1)$. Ce formalisme mathématique résout nativement l'un des problèmes récurrents de l'apprentissage par renforcement : l'explosion ou l'instabilité de la fonction de récompense. En utilisant directement $\zeta(t)$ comme signal de récompense, l'agent dispose d'une métrique de performance stable, continue et bornée.

Formalisation mathématique du couplage : Pour appliquer le Q-Learning à cet environnement dynamique, les concepts de l'article sont projetés dans un Processus de Décision Markovien (MDP) :

- Espace des États (S) : À l'instant t, l'état s_t est défini par le triplet $\{E(t), W(t), \zeta(t)\}$, où $E(t)$ représente l'ensemble des événements actifs et leurs 5 attributs quantifiables (gravité résiduelle, etc.), et $W(t)$ est la matrice d'interaction.
- Espace des Actions (A) : L'action a_t correspond aux leviers de régulation de l'opérateur, tels que l'injection forcée d'un événement compensatoire (neutralisation), la modification d'un attribut de gravité, ou la modification structurelle d'une relation d'interdépendance dans $W(t)$ (par exemple, l'atténuation d'un effet d'amplification).
- Fonction de Récompense (r_t) : La récompense immédiate renvoyée à l'agent est directement corrélée à l'évolution de la santé du système. Deux approches sont envisageables :
  1. *Récompense absolue* : $r_t = \zeta(t)$, incitant l'agent à maintenir le système le plus proche possible de l'état sain ($+1$).
  2. *Récompense différentielle* : $r_t = \zeta(t) - \zeta(t-1)$, récompensant toute action entraînant une trajectoire d'amélioration clinique de l'environnement.

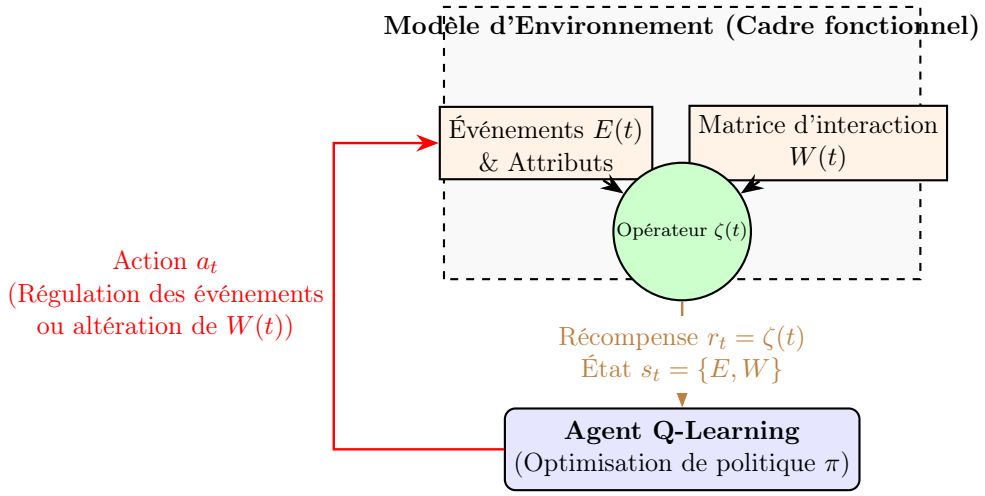


FIGURE 28 – Architecture d'intégration du Q-Learning sur le modèle de quantification fonctionnelle de l'état de santé.

Grâce à cette architecture, l'algorithme de Q-Learning apprend de manière empirique la meilleure politique de gestion des crises environnementales. Face à un choc (événement imprévu à forte gravité), l'agent sélectionnera l'action qui minimise la chute de $\zeta(t)$ à long terme, en tenant compte des phénomènes d'amplification ou de rétroaction codés dans la matrice $W(t)$.

7.5.5 Analyse des résultats

Cette sous-section est dédiée à l'évaluation critique des performances de cette approche. À travers l'examen conjoint de la trajectoire de convergence de la MAPE, de la structure de la Q-table

agrégée et de la distribution des visites d'états, nous analyserons la capacité de l'agent à explorer efficacement l'espace des solutions et à stabiliser les valeurs des paramètres α, β, γ et δ.

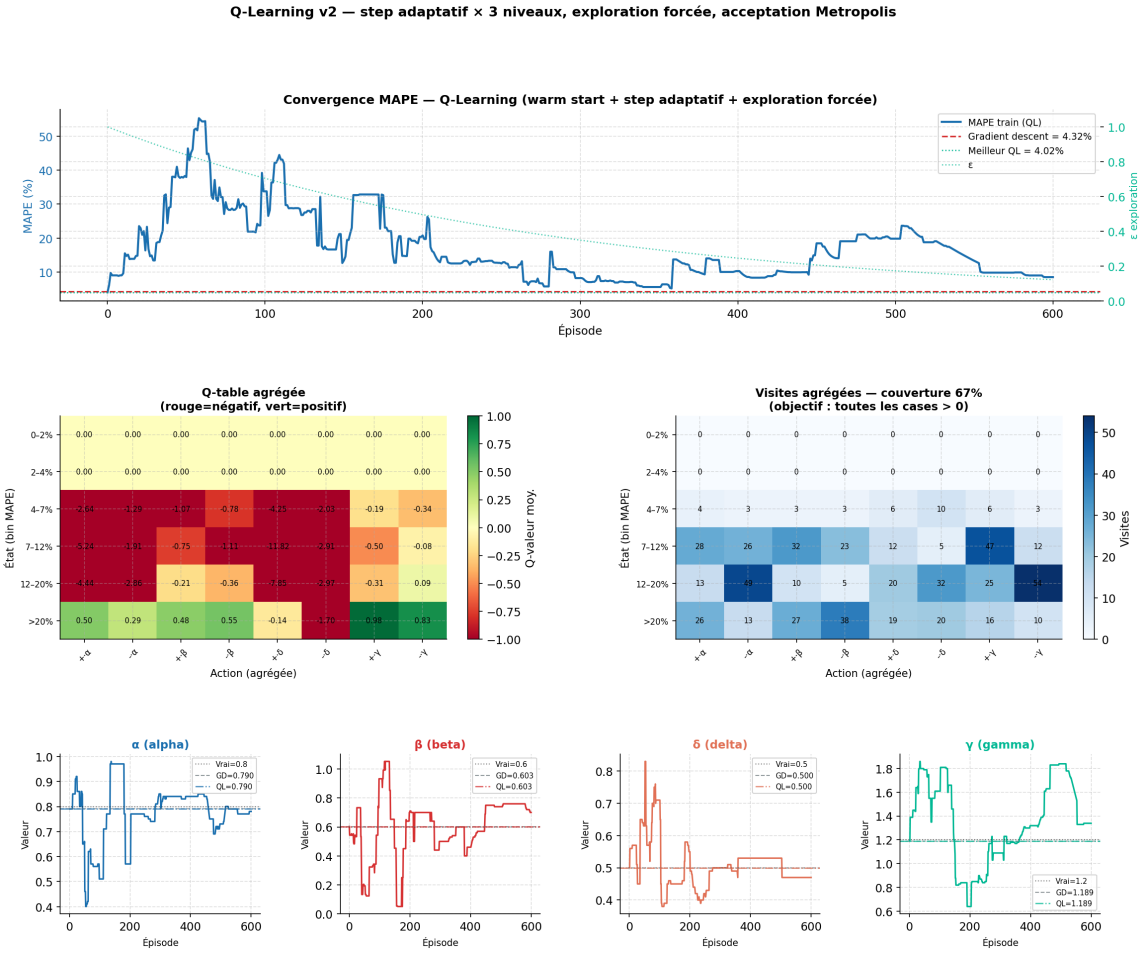


FIGURE 29 – Informations compilées en lien avec le Q-Learning

— Évolution des performances et des coefficients (premier graphique) : Le score maximal atteint jusqu'à présent est observé aux alentours de 350 épisodes. L'analyse des coefficients à ce stade est tout à fait cohérente avec ce résultat : vers le 350e épisode, les paramètres β, δ et γ ont quasiment retrouvé leurs valeurs initiales (celles ayant conduit au meilleur score historique), à l'exception du paramètre α qui se situe très légèrement au-dessus.

— Fréquentation des états et table des récompenses : Aucune case n'a été visitée parmi celles associées à une MAPE comprise entre 0 % et 4 %. Cela explique de manière directe les scores nuls (0) observés au sein de la table des récompenses située sur la gauche.

Ces éléments mettent en évidence qu'en début de processus, la correction de la MAPE est relativement aisée. Puisqu'elle est initialement élevée (et donc peu performante), la probabilité de converger vers des combinaisons de paramètres qui l'améliorent est nettement plus forte.

— Analyse de l'impact du paramètre δ : Quelle que soit l'interaction avec δ, le score demeure systématiquement négatif malgré un volume de visites relativement important. Il semblerait donc que la valeur de δ impacte négativement la MAPE. Cela tendrait à montrer une faiblesse structurelle du modèle lui-même, ou du moins de la manière dont le paramètre δ y est actuellement intégré.

TABLEAU 4 – Rapport entre la Q-valeur moyenne et le nombre de visites (Q-valeur/Visites)

État (bin MAPE)	$+\alpha$	$-\alpha$	$+\beta$	$-\beta$	$+\delta$	$-\delta$	$+\gamma$	$-\gamma$
0–2%	–	–	–	–	–	–	–	–
2–4%	–	–	–	–	–	–	–	–
4–7%	-0,6600	-0,4000	-0,3567	-0,2600	-0,7083	-0,2030	-0,0317	-0,1133
7–12%	-0,1871	-0,0735	-0,0234	-0,0483	-0,9850	-0,5820	-0,0106	-0,0067
12–20%	-0,3415	-0,0584	-0,0210	-0,0720	-0,3925	-0,0928	-0,0124	0,0017
>20%	0,0192	0,0223	0,0178	0,0145	-0,0074	-0,0850	0,0612	0,0830

L'analyse de ce tableau de ratios permet de tirer les conclusions suivantes :

— Coût de l'exploration en zone de haute précision : Plus l'algorithme progresse vers une MAPE faible (haute précision), plus les visites d'états deviennent pénalisantes (ratios négatifs plus marqués). Chaque action entreprise dans ces zones critiques dégrade plus fortement la Q-valeur moyenne, ce qui traduit une difficulté de l'agent à stabiliser ses gains.

— Problème de granularité des actions : Il semblerait que la taille des pas de modification des hyperparamètres $(\alpha, \beta, \gamma, \delta)$ ne soit plus assez fine pour permettre à l'agent d'accéder aux paliers supérieurs de performance (les plages de MAPE comprises entre 0 % et 4 %, restées inexplorées).

— Facteurs limitants : Ce défaut de convergence peut être attribué à deux causes principales :

1. Une décroissance exponentielle trop rapide du paramètre d'exploration ϵ, qui fige la politique de l'agent avant qu'il n'ait pu affiner ses choix.
2. L'effet de discrétisation (le découpage en "bins" de la MAPE), dont la grossièreté masque les gradients fins et empêche l'algorithme de percevoir de micro-améliorations.

Analyse approfondie de l'effet de discrétisation Le découpage de la MAPE en intervalles discrets (ou « bins ») introduit un défi classique en apprentissage par renforcement : le problème de l'agrégation d'états. Dans les zones de haute précision, ce mécanisme limite la convergence de l'algorithme à travers deux phénomènes majeurs :

— Le phénomène du « point aveugle » (*Blind Spot*) : La MAPE est une variable continue, tandis que la Q-table repose sur des états discrets. En regroupant les performances par intervalles, les variations internes à un même état deviennent invisibles pour l'agent. Par exemple, si l'agent passe d'une MAPE de 11,9 % à 7,1 %, l'amélioration réelle est massive ($\approx 5\,\%$). Pourtant, pour l'algorithme, l'état de départ et l'état d'arrivée restent identiques (l'intervalle 7–12 %). Sans une fonction de récompense extrêmement sensible aux variations continues sous-jacentes, l'équation de Bellman ne perçoit aucune progression, rendant l'agent mathématiquement « aveugle » à ses propres succès.

— L'effet de bord : La discrétisation crée une distorsion artificielle de la perception des distances. Une variation infime de 0,2 % (passer de 12,1 % à 11,9 %) provoque un changement d'état complet (12–20 % → 7–12 %) et est perçue comme une transition majeure. À l'inverse, un effort d'optimisation significatif de 4 % (passer de 11,5 % à 7,5 %) laisse l'agent dans le même état, sans aucune gratification. Cette incohérence perturbe la mise à jour des valeurs de la Q-table dans les zones proches de l'optimum, là où la précision des actions est pourtant cruciale.

Remarque 7.6 (Pourquoi ne pas simplement réduire les intervalles ?)**.** *Réduire la largeur des* bins *de MAPE est effectivement le premier levier auquel on pense, mais il se heurte à un compromis d'échantillonnage : avec seulement quelques centaines d'épisodes (Figure 29), une discrétisation plus fine multiplie le nombre d'états $s \in S$ sans garantir un nombre de visites suffisant par*

état, ce qui ralentit d'autant la convergence de l'équation de Bellman (35) *et peut, en pratique, dégrader la stabilité de l'apprentissage plutôt que l'améliorer. Deux pistes plus robustes sont envisageables : un raffinement* progressif *des bins au fil de l'entraînement (sur le même principe que le raffinement adaptatif de nœuds de la Section 7.3.3), ou - solution plus radicale, déjà identifiée en perspective (Section 9) - le remplacement pur et simple de la Q-table tabulaire par un approximateur continu de* $Q(s, a)$.

7.6 Adoption d'un nouvel événement

Jusqu'à présent, nous avons supposé que chaque événement appartenait de manière explicite à un cluster identifié. Cette hypothèse est toutefois restrictive, car en pratique de nouveaux événements peuvent apparaître sans correspondance directe avec une catégorie déjà observée.

Principe de représentation hybride.

Nous proposons de représenter un événement inconnu comme une combinaison lexicale de clusters existants. L'idée est qu'un nouvel événement peut être reconstruit à partir des structures déjà apprises dans l'espace des événements, en fonction de leur proximité conceptuelle.

Par exemple, un *tsunami* peut être interprété comme une combinaison d'un *séisme* et d'une *inondation*.

Loi de ressemblance lexicale.

Nous avons précédemment introduit une fonction de similarité définie entre deux événements qui quantifie leur proximité lexicale dans l'espace des événements :

$$\mathrm{Sim}(e_i, e_j) \in [0, 1].$$

À partir de cette quantité, on définit une mesure d'affinité entre un événement et un cluster comme une agrégation des similarités internes :

$$\mathrm{Sim}(e, \mathcal{C}_k) = \frac{1}{|\mathcal{C}_k|} \sum_{e_j \in \mathcal{C}_k} \mathrm{Sim}(e, e_j). \tag{36}$$

On note π_k ces poids de décomposition, afin d'éviter toute confusion avec les poids statiques ω_i des événements (Définition 6.3) : ils sont ensuite obtenus par normalisation :

$$\pi_k = \frac{\mathrm{Sim}(e_{\text{new}}, \mathcal{C}_k)}{\sum_{j=1}^{K} \mathrm{Sim}(e_{\text{new}}, \mathcal{C}_j)} \quad \text{avec} \quad \sum_{k=1}^{K} \pi_k = 1. \tag{37}$$

Ainsi, la décomposition s'écrit :

$$e_{\text{new}} \approx \sum_{k=1}^{K} \pi_k \, \mathcal{C}_k. \tag{38}$$

Exemple.

Pour un événement de type tsunami, on obtient typiquement :

$$e_{\text{tsunami}} \approx 0.6 \, \mathcal{C}_{\text{séisme}} + 0.4 \, \mathcal{C}_{\text{inondation}}. \tag{39}$$

Propagation de la gravité.

Dans ce cadre, la gravité associée à un événement composite est définie par combinaison pondérée :

$$\Gamma(e_{\text{new}}) = \sum_{k=1}^{K} \pi_k \, \Gamma_k, \tag{40}$$

où Γ_k représente la gravité associée au cluster $\mathcal{C}_k$.

Cette formulation permet de généraliser naturellement le modèle aux événements inconnus, tout en conservant la structure apprise dans l'espace des clusters.

8 Synthèse du modèle

Objet	**Définition**	**Espace**	**Origine**	**Réf.**
Événement e_i	(D, F, R, P)	$\mathbb{R}^4$	Auteur	Déf. 2.3
Gravité $\mathcal{G}_i(t)$	$\mathcal{D}_{\text{eff}}^{\alpha} F^{\beta} R^{\delta}/(1+P^{\gamma})$	$\mathbb{R}^+$	Auteur	Déf. 3.4
Matrice $\mathbf{W}(t)$	$[W_{ij}(t)]$	$\mathbb{R}^{N\times N}$	Auteur	Déf. 4.2
Gravité eff. $\widetilde{\mathcal{G}}_i$	$(\mathbf{I}+\mathbf{W})\mathbf{G}$	$\mathbb{R}$	Auteur	Déf. 4.3
Poids ω_i (statique)	$\in [-\omega_{\max}, \omega_{\max}]$	$\mathbb{R}$	Auteur	Déf. 6.3
Drap f^*	$\arg\min \bar{I}(f)$	$\mathcal{C}^{\infty}(\Omega)$	Auteur	Déf. 6.8
Poids norm. $\bar{\omega}_i$	$\omega_i/\|\boldsymbol{\omega}\|_1$	$\mathbb{R}$	Auteur	Déf. 6.4
État de santé ζ_λ	$\tanh(\frac{1}{\lambda}\sum_i \bar{\omega}_i \widetilde{\mathcal{G}}_i)$	$(-1,1)$	Auteur	Éq. (24)

TABLEAU 5 – Synthèse des objets mathématiques. Tous les éléments sont des contributions originales de l'auteur sauf mention contraire.

Chaîne de transformation :

$$\{e_i\} \xrightarrow{\Gamma_{\hat{\theta}_{k(i)}}(t)} \mathbf{G}(t) \xrightarrow{\mathbf{I}+\mathbf{W}(t)} \widetilde{\mathbf{G}}(t) \xrightarrow{\langle\bar{\boldsymbol{\omega}},\cdot\rangle} S(t) \xrightarrow{\tanh(\cdot/\lambda)} \zeta_\lambda(E(t)) \in (-1,1). \tag{41}$$

9 Discussion et conclusion

9.1 Synthèse des contributions

Ce travail a proposé un cadre mathématique unifié pour la modélisation quantitative d'un environnement dynamique. Trois apports structurent l'ensemble de la construction.

Premièrement, la représentation *événementielle* de l'environnement (fondée sur cinq attributs quantifiables et un opérateur de caractérisation Γ intégrant directement la dynamique temporelle via la gravité résiduelle $\mathcal{D}_{\text{eff}}(t)$) permet de s'affranchir d'une modélisation explicite du cadre spatial, tout en restant applicable à des domaines aussi variés que la finance, l'écologie ou la gestion de risques.

Deuxièmement, la matrice d'interaction $\mathbf{W}(t)$ formalise les effets croisés entre événements coexistants (amplification, rétroaction, neutralisation), une dimension souvent négligée dans les approches purement additives.

Troisièmement, l'opérateur ζ_λ, fondé sur tanh et enrichi par un mécanisme de dilatation adaptative, synthétise l'ensemble de ces informations en un indicateur borné et interprétable, dont la construction (poids statiques normalisés en L^1, drap variationnel pour l'initialisation des nouveaux événements, lissage par splines adaptatives) a été validée par une série d'expériences préliminaires atteignant une MAPE de 3,35 % à 4,32 % selon la configuration testée, pour un coefficient de détermination $R^2 = 0{,}9913$.

9.2 Limites actuelles du modèle

Plusieurs limitations, déjà évoquées ponctuellement au fil du texte, méritent d'être rassemblées et discutées de façon plus systématique.

— Subjectivité du cadre, de l'ordre de grandeur et des poids initiaux. Le cadre $\mathcal{C}$ (Définition 2.2), l'ordre de grandeur h (Remarques 2.3 et 2.4) et les poids initiaux ω_i (Définition 6.3) demeurent des choix largement exogènes au modèle. Le drap variationnel (Section 6.6) atténue ce problème pour les poids des nouveaux événements en interpolant les poids observés, mais ne supprime pas la dépendance initiale à une base d'événements déjà annotée, ni la nécessité pour l'utilisateur de fixer $\mathcal{C}$ et h a priori.

— Sensibilité du clustering lexical. L'approche par similarité de Jaccard (Proposition 3.1) repose sur un seuil τ dont le choix reste empirique : un seuil trop bas fusionne des familles d'événements aux lois de gravité distinctes, tandis qu'un seuil trop élevé fragmente artificiellement des clusters homogènes.

— Complexité quadratique de la matrice d'interaction. Comme indiqué en Remarque suivant l'Algorithme 1, le calcul de la gravité effective $\widetilde{\mathbf{G}}(t) = (\mathbf{I}+\mathbf{W}(t))\mathbf{G}(t)$ est en $O(N(t)^2)$ dans son implémentation naïve. Pour des environnements à très grand nombre d'événements actifs, une exploitation de la parcimonie de $\mathbf{W}(t)$ (la plupart des paires d'événements n'interagissant pas) serait nécessaire pour garantir le passage à l'échelle.

— Discrétisation et agrégation d'états en Q-Learning. L'analyse détaillée en Section 7.5 a mis en évidence le phénomène du « point aveugle » : le découpage de la MAPE en intervalles discrets masque les gradients fins et limite la capacité de l'agent à distinguer de réelles améliorations dans les zones de haute précision (MAPE $< 4\,\%$), sans qu'une simple réduction de la largeur des intervalles suffise à résoudre le problème (Remarque 7.6). Le remplacement de la Q-table tabulaire par une approximation continue de $Q(s, a)$ (par exemple un

réseau de neurones [1], à la manière du Deep Q-Learning) constituerait une réponse plus robuste à cette limitation.

— Fonction de perte asymétrique non encore intégrée à la calibration. Le critère d'asymétrie introduit en Section 6 (Équation (23)) reste, à ce stade, un cadre conceptuel : la calibration par cluster (Définition 3.7) continue de s'appuyer sur la MAPE symétrique. L'intégration explicite de $\ell(\hat{g}, g)$ dans la procédure d'optimisation (en particulier pour les événements à fort impact négatif, où $c_- > c_+$ - voir la Remarque 6.6 pour des pistes de calibration de ce rapport) permettrait de pénaliser plus sévèrement les sous-estimations et d'aligner la calibration sur les enjeux opérationnels de gestion de risques évoqués en introduction.

— Absence de validation sur données réelles. L'ensemble des résultats présentés (Sections 6 et 7) repose sur une base d'événements générée aléatoirement, structurée autour de trois clusters synthétiques (financier, climatique, sanitaire). Si cette approche permet de valider la cohérence interne du modèle et la stabilité de sa calibration, une confrontation à des corpus d'événements réels, annotés par des experts ou extraits de bases historiques, reste nécessaire pour évaluer la portée pratique du cadre proposé.

9.3 Perspectives

Plusieurs directions de recherche découlent naturellement des limites identifiées ci-dessus.

À court terme, l'automatisation du choix du seuil de similarité lexicale τ, l'automatisation du calcul de l'ordre de grandeur caractéristique h à partir du cadre $\mathcal{C}$ (Remarque 2.4), et l'intégration de la perte asymétrique dans la calibration par cluster apparaissent comme les extensions les plus directement accessibles.

À moyen terme, le remplacement de la Q-table discrète par un approximateur continu permettrait de traiter des environnements de taille réaliste.

Enfin, à plus long terme, la validation du modèle sur des jeux de données réels, couplée à une automatisation de l'opérateur Ψ par un modèle de traitement du langage naturel (Définition 3.1), ouvrirait la voie à un système opérationnel de suivi continu de l'état de santé d'un environnement, qu'il soit financier, écologique ou organisationnel.

9.4 Conclusion

En définitive, ce travail propose une formalisation mathématique cohérente et modulaire d'un environnement dynamique, depuis la caractérisation individuelle des événements jusqu'à leur synthèse en un indicateur unique et borné.

La hiérarchie *cadre–événements–axe temporel*, l'opérateur de gravité résiduelle Γ, la matrice d'interaction $\mathbf{W}(t)$ et l'opérateur d'état de santé ζ_λ constituent les briques d'un cadre extensible, dont la pertinence a été confortée par des résultats expérimentaux préliminaires encourageants.

Les limites identifiées, la subjectivité de certains choix initiaux, le coût quadratique des interactions, l'agrégation d'états en apprentissage par renforcement ne remettent pas en cause la validité du cadre formel, mais en circonscrivent le périmètre d'application actuel et tracent les axes d'un développement futur.

Annexes

A.1 Propriétés de la forme fonctionnelle de Γ (Définition 3.3)

Démonstration. (1) Monotonie : $\partial\mathcal{G}/\partial\mathcal{D} = \alpha\mathcal{D}^{\alpha-1}\mathcal{F}^{\beta}\mathcal{R}^{\delta}/(1+\mathcal{P}^{\gamma}) > 0$, idem pour $\mathcal{F}$ et $\mathcal{R}$. (2) Décroissance en $\mathcal{P}$: la dérivée partielle est ≤ 0 (strictement pour $\mathcal{P} > 0$). (3) Positivité : tous les facteurs sont positifs. (4) $\lim_{\mathcal{P}\to+\infty}\mathcal{G} = 0$, $\lim_{\mathcal{P}\to 0}\mathcal{G} = \mathcal{D}^{\alpha}\mathcal{F}^{\beta}\mathcal{R}^{\delta}$. □

A.2 Preuve de la Proposition 4.1

Démonstration. En ajoutant $W_{ii} = 0$ dans la somme de la Définition 4.3 : $\widetilde{\mathcal{G}}_i = \sum_j (\delta_{ij} + W_{ij})\mathcal{G}_j$, soit $\widetilde{\mathbf{G}} = (\mathbf{I} + \mathbf{W})\mathbf{G}$ en notation matricielle. □

A.3 Preuve de la Proposition 6.1

Démonstration. (i) $|\tanh(x)| < 1$ car $e^x + e^{-x} > |e^x - e^{-x}|$, image $(-1, 1)$. (ii) $\tanh(x) > 0 \iff x > 0$ (préservation du signe). (iii) $\tanh'(x) > 0$ (strictement croissante, injective) ; surjectivité par le théorème des valeurs intermédiaires. □

A.4 Preuve de la Proposition 6.2

Démonstration. (i) Pour $c > 0$, $\bar{\omega}_i = c\omega_i/(c\|\boldsymbol{\omega}\|_1)$ inchangé. (ii) $\omega_{N+1} = 0$ n'affecte pas $\|\boldsymbol{\omega}\|_1$. (iii) $|S| \leq \sum_i |\bar{\omega}_i||\widetilde{\mathcal{G}}_i| \leq \max_i |\widetilde{\mathcal{G}}_i|$ car $\sum_i |\bar{\omega}_i| = 1$. □

Bibliographie

Références

[1] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.

[2] Rudin, W. (1976). *Principles of Mathematical Analysis* (3rd ed.). McGraw-Hill.

[3] Horn, R. A., & Johnson, C. R. (2012). *Matrix Analysis* (2nd ed.). Cambridge University Press.

[4] Watkins, C. J. C. H., & Dayan, P. (1992). Q-Learning. *Machine Learning*, 8(3–4), 279–292.

[5] Virtanen, P. et al. (2020). SciPy 1.0. *Nature Methods*, 17, 261–272.

[6] MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proceedings of the 5th Berkeley Symposium*, 1, 281–297.

[7] Evans, L. C. (2010). *Partial Differential Equations* (2nd ed.). AMS.